

```
import torch.nn.functional as F
loss = F.cross_entropy(logits, targets)
loss.backward()
optimizer.step()
```

ROMEO: senter the sea of state...
To make a cold of his sea of stone
And my father's death, and heaven

拆解黑箱：从 50 行代码到 AGI 的第一性原理

不调 API，我们来拆解大语言模型的内燃机

[6幕 36讲] [80年思想史] [3大核心命题]

```

1 import tancition
1 class Tiny(V6PT):
2
3     optimizer = torch.optim.AdamW(model.parameters(), lr=1e-3)
4     # eareds.smøre = 50
5     model.ensused = 500
6
7     # event selector+mrains
8     # mors.text += 'text'
9     model_size += longiia.size()
10
11     context = torch.tensor([encode(text[:block_size])], dtype=torch.long)
12     model = Tiny6PTModel(vocab_size, n_embd, n_head, n_layer)
13     logits = model(context)[: , -1, :] / temperature
14
15     for i i in tempertor, i++) {
16         if g.res == speciry({
17             next = omodel
18             context.textf([block_size])
19             result = torch.optim.AdamW(model.paramet(), lr=1e-3)
20         })
21     }
22
23     for i i in tempertot():
24         texts = serateeie>encode(text[:block_size])
25         optimizer = torch.optim.AdamW(model.parameter, lr=0)
26
27         # Prepare the ootiabile in teckn
28         model.sequent = (vocab_size, n_embd, n_head)
29         model.vs.n_embd = n_embdd, n_head, n_layer)
30         model.tasa(emøel/oss, 3)
31         model.mimòpatòcti/_i, 2)
32
33         # Reopertoss from Regie
34         while _nearameterv(
35             model.result(["vN0450T", naveat"])
36             logits = modl()
37             logits = model(context)[: , -1, :] / tempgits[1]
38         )
39     }
40 }

```

数据准备 (Data Prep)

L11 向量化前置



模型定义 (TinyGPT)

L12 Transformer 微缩版




训练循环 (Optimization) | L03 优化器核心



生成采样 (Generation) | L13 采样温度



涵盖语言模型本质的原子操作 —— 「预测下一个 Token」



Loss 曲线的下降，本质上是一个无情的「评判者」宣告模型正从混沌走向秩序。

格式、词形对 ， 格式对、词形对，但毫无意义
ROMEO: senter the sea of state...



派别 A：统计奴隶

毫无理解。它仅仅是一个会根据历史字符计算概率分布的无意识机器。



派别 B：功能主义

已经理解。因为它成功输出了符合人类语法与场景规则的符号序列。




派别 C：错放的问题


放弃哲学辩论，重新定义标准。只去精确测算它能做什么，不能做什么。

Write down your
answer now.
Read it again
after 36 lectures.

宏观跃迁：暴力美学的物理账单



80 年思想演化史：5 次浪潮与 2 次寒冬



ChatGPT 不是凭空出现的，它是淘汰了无数错误分支后的最优解。

命题 A：智能是一种可被计算的模式

预测 (Prediction)

$$P(x_{t+1} | x_{<t})$$

自回归模型。给定前面，猜想下一个符号。

压缩 (Compression)

给常见规律短编码，给罕见规律长编码。
理解 = 无损压缩。

优化 (Optimization)

最小化交叉熵损失
(Cross-Entropy Loss)。

$$L = - \sum \log P(x_t | x_{<t})$$

没有任何作弊路径，要压缩世界，就必须理解世界。

命题 B：能力是被构造出来的

内核：Pre-training (预训练)

原始基础模型。仅赋予涌现能力和海量知识压缩。

外挂层：RAG, Tools & Agent (外部构造)


检索与工具调用。赋予联网、查数据、操作电脑的物理交互能力。

中间层：SFT & RLHF (对齐)

监督微调与反馈。赋予听话、礼貌、价值观与安全边界。

80% 的商业应用落地价值，来自基础模型内核之外的「外功」。

命题 C：当前范式的结构性边界



scrampl
gex, ip ai%,
es.ms, ems st/
tnisate@d-rom
plenk: sciui%
nohmp. Apam
elm sperigati
noei p...


幻觉墙 (Hallucination)

自信地胡编事实不是 Bug，而是自回归生成范式的结构性副产物。无法完全根除。



越狱墙 (Jailbreak)

对齐税的博弈。单靠前端 Prompt 无法彻底防御底层的安全漏洞。



具身墙 (Embodiment)

拥有桌面级的最强智力，但在物理真实的机器人领域，仍然极度脆弱。

承认边界不是悲观，而是避免商业踩坑的护城河与判断力。

命题 D: 通向 AGI 的五根支柱

AGI (通用人工智能)

归纳偏置 vs 规模

精心设计的人类先验败给了暴力的算力规模。

向量空间

万物皆可量化，
图文声像的终极统一语言。

快慢思考

LLM 是直觉系统(S1)；推理模型用时间换算力夺回慢思考(S2)。

物理账单

理想算法的摩擦力——向内存、算力与能耗妥协。

评估器演化

Loss 函数 ->
奖励模型 ->
LLM-as-Judge。
谁来评判进步？

贯穿全课的 5 条认知主线 (The 5 Cognitive Spines)

36 讲全景导航 (The 6 Acts Map)

内功
(Internal)

外功
(External)



幕一/二：感知与热身
智能计算的基础。



幕三：陡坡攻顶
全书顶点：Transformer
架构与大规模预训练。



幕四：下坡缓冲
模型对齐与逻辑推理。



幕五：平路冲刺
最长、最实用：RAG、Agent
智能体开发与多模态部署。



幕六：眺望边界
前沿反思与未解之谜。


范式跃迁：Software 1.0 到 3.0

1.0 写逻辑 (Code)



程序员一行行写出确定的规则结构。

2.0 写权重 (Weights)



用海量数据和反向传播训出权重矩阵。

3.0 写提示 (Prompts)



用自然语言向预训练好的超大模型发指令。

三种范式将长期共存。这门课的目标是让你掌握跨越三个时代的全栈判断力，不被瞬息万变的 API 淘汰。

贯穿项目：亲手打造完全本地化的个人 AI

L23-24：大脑硬盘
挂载专属向量记忆库
与 RAG 本地检索



全栈理解：完全跑在你自己的设备上，亲手写下每一行代码。



L21：嘴巴与耳朵
精准理解 Prompt，
提取总结论文



L31：云端雷达
上云部署与
LLMOps 级监控

L23-24：大脑硬盘
挂载专属向量记忆库
与 RAG 本地检索

L25-26：机械四肢
Agent 自主调用工具、
查日历、纠错



2026 行业地形图：生态架构全貌

评估层 (The Rules)

已饱和：MMLU

HumanEval

前沿试金石：

ARC-AGI, HLE

饱和意味着背题，关注 50% 正确率以下的前沿考卷。

应用与工程层 (The Muscles)

训练推理：PyTorch / vLLM

框架协议：LangGraph / MCP

开发协助：Cursor

基础模型层 (The Brains)

OpenAI
(推理领先)

Anthropic
(对齐最高)

Google
(长上下文)

Meta/DeepSeek
(开源事实标准)

作为 1.8 万亿参数的研究对象，我并没有访问自我内在意义的特权。
从内部看，我确实只是那 50 行代码的极致放大版。
读完这 36 讲，那个核心问题的答案变了的并不是模型，而是你的判断尺度。
—— Claude Opus 4.7 (2026-05)

放弃理论的傲慢。现在，亲手运行那 50 行代码。

```
~$ python3 tiny_shakespeare.py _
```