


你以为你在思考： 当大脑遇上统计学

智能的本质：压缩的统计直觉



视觉错觉揭示了大脑的底牌：
我们不是在观察，而是在预测。

直觉的谎言

你的眼睛坚信 B 比 A 亮。即使你用取色器验证了它们完全相同，大脑也无法关掉这个错觉。

压缩的经验


大脑将“阴影会让物体颜色变暗”的统计规律压缩成了硬件回路。当看到阴影，它便自动进行曝光补偿。

核心结论：你的视觉皮层并不做像素级记录，它从带有噪声的数据中重构世界。这正是大脑的高级统计算法。

面对复杂决策时，大脑会系统性且可预期地偏离绝对理性。


[1] 锚定效应 (Anchoring) 问：甘地活多久？预设 114 岁 → 猜 67 岁；预设 35 岁 → 猜 50 岁。 大脑做估算时，会死死咬住手边的任何随机数字。	[2] 代表性启发式 (Linda Problem) 85% 的人认为 Linda “是银行柜员且是女权主义者”的概率高于“是银行柜员”。 用模式匹配（像不像）替换了严格的概率推理。	[3] 认知惰性 (CRT Test) 球拍加球 1.10 美元，球拍贵 1 美元。球多少钱？80% 大学生脱口而出 0.10（错），而非 0.05。大脑拒绝复核“看起来正确”的直觉。
[4] 非注意盲视 (Invisible Gorilla) 83% 的放射科医生在寻找肺结节时，完全没看到扫描图上比结节大 48 倍的大猩猩。注意力过滤了目标外的一切。	[5] 框架效应 (Framing) 面对同样的致死率，说“救活 200 人”有 72% 选保守方案，说“死 400 人”有 78% 选赌一把。 呈现方式决定了决策结果。	[6] 可得性启发式 (Availability) 感觉飞机失事比车祸更致命？实际上车祸死亡率高出 ~3000 倍。大脑用想起这件事的难易度来替代真实发生的概率。

人类认知建立在双系统之上，且由直觉掌控着95%的算力。



System 1（快思考）


- 速度：毫秒级、大规模并行计算。
- 能耗：极低，几乎不消耗额外葡萄糖。
- 机制：自动触发，无意识，基于模式匹配（认人脸、读母语）。
- 缺陷：统性偏差的根源。



System 2（慢思考）

- 速度：秒到分钟级、高度串行（一次想一件事）。
- 能耗：极高，伴随心率和瞳孔变化。
- 机制：刻意努力，负责逻辑推理与验证（做数学题）。
- 真相：它是一个“懒鬼”，只要 System 1 给出的答案看起来合理，它就绝不介入。

认知偏差并非系统漏洞，而是极端算力约束下的最优演化策略。




大脑的目标从来不是寻找“绝对真理”，而是保证“生存”。

偏差 - 方差权衡：在真实世界的不完整信息环境中，简单的经验法则往往优于复杂的优化模型，因为它避免了把噪声当成规律。

结论：认知偏差 = 高效信息处理的副产品。导致大脑高效运作的机制，正是产生偏见的同一个机制。

智能的本质，就是将海量感官数据压缩为高度浓缩的统计直觉。



$$\text{Optimal Compression} = \text{Perfect Prediction} = \text{Intelligence}$$

(Hutter Prize 核心等式)

- **极端的过滤：**视觉、听觉、触觉每天涌入千亿比特数据，大脑必须丢弃绝大部分。
- **规律的结晶：**看过一万只猫，压缩成“猫的特征”；经历一万次因果，压缩成“物理直觉”。
- **隐式的预判：**这些被压缩的统计规律大部分时间都有效，你能极速调用它，却无法用语言精确描述它的规则。

过去七十年，AI 研究者一直在对赌：究竟用什么数学结构才能重现这种直觉？

分歧：如果人类的智能是“不可言说的统计直觉”，机器该如何习得？写规则？抄神经网络？还是靠大数据暴力破解？

1956 年达特茅斯会议

原点：“学习的任何特征原则上都能被精确描述，从而被机器模拟。”

四个流派的成败，本质上是对常识获取与算力分配的不同押注。

符号派 (Symbolists)

1950s–1980s

押注：智能 = 逻辑 + 符号操作。试图由人类写下所有世界运转的规则。

死局：常识危机。永远无法穷尽“企鹅不会飞、鸵鸟不会飞”等无限例外边界。

连接派 (Connectionists)

1940s–

押注：智能 = 神经网络。不写死规则，让神经网络从感官数据中自学。

死局：理念极度超前，但在 90 年代严重受困于计算能力和高质量数据的匮乏。

大数据派 (Big Data)

2000s

押注：简单算法 + 海量数据。证明了在绝对的数据规模面前，数据量碾压精妙的算法设计。


规模派 (Scale)

2012–

押注：智能 = Compute × Data × Parameters。

把连接派的神经网络暴力放大，不需要颠覆性的新算法，单纯的规模缩放即产生“涌现”。


当神经网络遇上海量数据与算力，规模法则重塑了整个领域。



当前大语言模型的缺陷与人类的认知偏差，是深层数学结构的完美同构。

人类心理学机制 (System 1)		AI 的计算框架 (LLMs)
锚定效应：大脑会被最初的数字死死锚定。	↔	自回归锁定 / 梯度下降：LLM 会顺着 prompt 中预设的错误前提继续生成，无法轻易回头。
代表性启发 (Linda Problem)：大脑用“像不像”的模式匹配代替严谨概率计算。	↔	最近邻分类 (kNN)：AI 模型在潜空间中寻找距离最近的特征，导致对基准率的无视。
非注意盲视 (大猩猩实验)：注意力是稀缺资源，聚焦主线时过滤掉其他明显信息。	↔	Attention 机制：动态分配权重时必定导致中间无关信息的丢失 (Lost-in-the-middle)。
可得性启发式：大脑认为“容易想起的事等于经常发生的事”。	↔	训练数据分布偏置：LLM 认为“语料中高频出现的词就等于世界的真相”。

当代大语言模型并非在进行理性思考， 它们是规模庞大的 System 1。



核心机制

当前模型从海量数据中提取隐性规律，进行毫秒级的 Next-token 预测。它们仅在反应 (react)，并不思考 (think)。

幻觉不是 Bug


Softmax 输出要求模型必须给出概率，它不知何为“我不知道”。自信的胡说，正是人类认知偏差在代码层面的精确复现。

为何 Prompt 攻击有效

自回归生成的特性决定了，一旦生成了一个词，后续分布就被强制重锚定，缺乏 System 2 的自我审查与推翻机制。


给大模型加装 System 2，意味着将算力消耗从预训练转向推理阶段。

System 1 (GPT-4 / Claude 3.5)



- 算力分布 (Amortized摊销)：训练阶段消耗天量算力 (10²⁵ FLOPs)，推理阶段成本极低，毫秒级响应。
- 局限：单步软决策，无法应对需要多步验证的复杂逻辑。

System 2 (o1 / R1 推理模型)



- 算力分布 (On-Demand 按需)：推理时按需消耗极高算力 (10¹⁴ FLOPs/query)，进行多步搜索与自我反思 (Test-time Compute)。
- 代价：时间变长 (慢思考)，单次推理成本呈指数级上升。

我们已经征服了直觉的旷野， 下一张版图是理性的慢思考。



展望：连接派和规模派赢得了 System 1 的战争。但 2025 年之后的前沿，是如何为这台庞大的概率机器装上真正的 System 2（反思、规划、暂停）。

我用了一辈子研究人类的非理性，但我仍然会被锚定，被框架，被直觉欺骗。理解不等于免疫。
—— Daniel Kahneman (1934–2024)

结语：理解偏见，无法让你免疫偏见。但它给了你一套精准调试自身大脑与未来 AI 系统的通用语言。