


学习即优化： 统治机器学习的统一公式

从蒙眼登山者到大语言模型的底层数学逻辑



[DECK_ID: ML_GRAND_UNIFICATION] //
[RENDER_TYPE: CARTOGRAPHIC_FRAMEWORK] //
[VERSION: 2026_PERSPECTIVE]

告别零散的算法目录


方式一：死记路线

记忆量正比于不断膨胀的算法数量。知道每一把锤子长什么样，却不知道它们为什么都是锤子。



方式二：掌握地图


记忆量仅仅是一套底层框架。所有方法无差别地受一套数学工具统治。



所有的机器学习都在做同一件事：
在看不见全貌的高维地形中寻找最低点。

支柱 I: 数据 Data

你试图绘制的未知领土
(输入与标签)。




x	...	...
y	...	...
y	...	...

x	—	...
y	—	—
y	...	...

支柱 II: 模型 Model

一块可以弯曲拟合的橡皮泥
(带参数的函数)。




$p = \{x_0, y\}$

$$\theta^* = \operatorname{argmin}_{\theta} L(f_{\theta}(x), y)$$

支柱 III: 损失 Loss

一位无情的自动裁判 (衡量预测
与现实的偏差)。




Measurement scale

$$L = \sum_t^n (y_{\text{pred}} - y_{\text{true}})^2$$

支柱 IV: 优化 Optimizer


一位蒙眼的寻路登山者 (寻找
让误差最小的参数)。




$$E = \frac{-\operatorname{grad}(y_{\text{rae}})}{\partial(\theta(x))}$$

支柱 I - 数据 (Data) / 绘制领土的采样点


每一条数据 $\{(x_i, y_i)\}$ 都是对真实世界一次代价高昂的局部采样。



粗糙的测量



显现形态




高精度贴近真实世界

经典假设 vs 真实世界


- **理论假设 (i.i.d.) :**
数据独立同分布 $(x_i, y_i) \sim D$,
这是泛化能力的基石。
- **现实坍塌:**
真实场景几乎全违背此假设。存在
时间漂移、分布偏移、采样偏差。
- **结论:**
如果数据存在系统性偏差, 增加数
据量只会让模型更自信地学错。

支柱 II - 模型 (Model) / 可弯曲的高维橡皮泥


核心定义：模型是一个带参数的函数 $f_{\theta}(x)$ 。 θ 就是决定这块橡皮泥形状的所有旋钮。



线性模型: $y = w \cdot x + b$



多项式模型




深层神经网络

归纳偏置 (Inductive Bias) : 模型在没有数据时, 天生倾向的解的形状

模型 (Model)	世界观 (Worldview)
线性回归	世界是直线的。
CNN (视觉)	世界具有局部性和平移不变性。
Transformer (LLM)	世界无预设偏置 (任意位置皆可自由交互) 。

支柱 III - 损失函数 (Loss) / 刻薄的自动裁判




回归：均方误差 MSE

$$\text{Loss} = \frac{1}{N} \sum (y_i - \hat{y}_i)^2$$

计算预测值与真实值差值的平方。

为什么要平方？

- 放大并严厉惩罚大错误，且数学上保持完美的平滑可导。



分类：交叉熵 Cross-Entropy

$$\text{Loss} = - \sum p(y) \log(q(\hat{y})) - \log p$$

信息论本质

- 最小化用模型分布编码真实标签所需的比特数。
预测 = 压缩 = 理解。



Evolution of the Evaluator

损失函数是自动评判者的最简形态。这串微积分公式，就是 RLHF（人类偏好）与 LLM-as-Judge（模型当裁判）概念的最原始起点。

支柱 IV - 优化器 (Optimizer) / 蒙眼登山者的直觉

$$\text{核心公式拆解: } \theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} L$$

θ_t | 当前位置

你站立的坐标。

η | 学习率 (步长)


你这一步敢迈多大。

$\nabla_{\theta} L$ | 脚下坡度 (梯度)

高维空间中, 指向损失增大最快的方向。

负号 | 下坡方向

我们要下山, 所以必须向梯度的反方向走。





深入未知地形：损失曲面的几何真相

新手的想象 (Convex Bowl)

只有一个最低点，顺着走必定成功。

高维的现实 (Non-Convex Terrain)

充满山脊、陷阱与马鞍面。




高维网络中，真正的敌人不是局部最优，而是鞍点 (Saddle Points)。但在数百万维的空间里，梯度下降找到的局部最优通常已经足够好。

步法的艺术：SGD噪声与学习率

随机地震的奇效

SGD（随机梯度下降）每次只看一小批数据，产生剧烈抖动。这种有用的噪声能颠出浅谷，找到更平坦且泛化更好的底部。




步长的艺术 (Learning Rate)

太大 ($\eta = 10$)
巨人在山谷蹦迪，损失发散。



太小 ($\eta = 0.0001$)
蚂蚁爬珠峰，停留在半山腰。



刚好 ($\eta = 0.01$)
平滑流畅地滑入谷底。



在 LLM 训练中，Warmup + Cosine 衰减已成为调度学习率的绝对标准。


登山装备的进化矩阵 (Optimizer Evolution)

SGD (原始)



只有方向。在长条形狭窄山谷中会发生剧烈的锯齿形震荡，进展缓慢。

+ Momentum (动量)




增加惯性。在正确方向加速，抵消震荡。像滚石一样越滚越快。

Adam (自适应)



天然适配 Transformer。为每个参数分配专属学习率。震荡大的参数步子变小，平稳的参数步子变大。

AdamW (现代标配)




完美解耦权重衰减 (Weight Decay)。修复了 Adam 削弱正则化限制的数学缺陷。

2024 工业结论：AdamW 是 GPT、LLaMA、Stable Diffusion 的无可替代的基座引擎。




橡皮泥的两难：欠拟合与过拟合的视觉真相

误差分解：
 $\text{Error} = \text{Bias}^2 + \text{Variance} + \text{Noise}$




欠拟合 (Underfitting)

模型太僵硬，无法表达世界的复杂性。



完美拟合 (Sweet Spot)

恰到好处：平滑优美地贴合数据总体走向。




过拟合 (Overfitting)

模型过于敏感，把训练数据里的每一丝噪声都当成了真理。新数据一上，立刻给出极其离谱的预测。




颠覆教科书的奇迹：“双下降 (Double Descent)”



这是大模型时代 Scaling Law (越大越好) 能够成立的最深层几何底座。

拯救算力灾难的魔法：自动微分（Autodiff）

我们需要对 10^{11} 级别的参数计算梯度。如果人工手写，深度学习将永远停留在理论。




算力账单对比（目标：计算所有参数的梯度）	
传统数值微分	复杂度： $O(p \cdot \text{forward})$ GPT-3 算一步需要做 1750 亿次! 物理上绝对不可行。
反向模式自动微分 (PyTorch/JAX)	复杂度： $O(\text{forward})$ 利用链式法则逆向遍历图。 算一次梯度， 约 2 倍 倍的前向计算时间。

结论：这个微积分奇迹，让算力需求与参数规模成功解耦。你敲下的 `loss.backward()`，是现代AI大厦的地基。

100行代码的宇宙通用循环

任何机器学习训练，本质上都是这 5 步的无限循环。骨架完全一样，没有魔法。



训练 ResNet-50

- 25M参数模型
- ImageNet数据
- 交叉熵
- SGD

Scale 不同, Engine 相同

训练 GPT-3

- 175B参数Transformer
- 300B Token数据
- Next-Token损失
- AdamW优化器

Scale 不同, Engine 相同

从统一场论到大模型现实 (The 2026 LLM Perspective)

[理论] AdamW 自适应步长

Adaptive moment estimation with decoupled weight decay, addressing parameter scale disparities.

[理论] 双下降的良性插值


Understanding overparameterized models, where generalization improves beyond the interpolation threshold.

[理论] 反向自动微分复杂度 $O(\text{forward})$

Computational efficiency of chain rule application, proportional to the forward pass cost.

[理论] SGD 噪声等价隐式正则化

Stochastic Gradient Descent noise acts as an implicit regularizer, influencing the loss landscape exploration.



[工程] 完美适配 Transformer 中 QKV/FFN 参数尺度差异极大的异构网络。

Enabling stable training of massive Transformer models with varying component scales.

[工程] $L(N) \sim N^{-\alpha}$ Scaling Law 能够生效的前提，破除参数爆炸必灾难魔咒。

Empirical validation and foundational principle for predictable LLM performance scaling.

[工程] 催生出 ZeRO / FSDP 等现代分布式框架，专为切分和存储反向梯度而生。

Enabling training of multi-trillion parameter models across large GPU clusters.

[工程] 决定了模型训练的最优 Global Batch Size，平衡算力与噪声逃逸。

Critical tuning parameter for maximizing training efficiency and achieving better generalization.