

认知校准：世界上大多数 ML 应用跑的不是深度学习。

真实世界的隐形底座：穿越 LLM 迷雾的结构化数据指南

(The Invisible Foundations: Navigating Structured Data Beyond the LLM Hype)



全球实际部署的 ML 系统中，排名前三的应用：

1. 时序预测（电力、物流、销量）
2. 推荐系统（电商、短视频）
3. 搜索与广告（CTR 预估）

千亿产业的底层依然是由 GBDT、协同过滤和 ARIMA 统治。最有用的，往往不是最酷的。

工业 AI 的隐藏齿轮：四大核心领域全景图

领域 (Domain)	经典统计基线	2024 工业统治者	基础模型尝试
时序预测 (Time Series)	ARIMA / Kalman	GBDT (XGBoost/LightGBM)	Chronos / TimeGPT
推荐系统 (RecSys)	基于物品的 CF	协同过滤 + 矩阵分解 + 深度混合	LLM 冷启动生成
异常检测 (Anomaly)	z-score / 3σ	Isolation Forest / One-Class SVM	Autoencoder 重建
图分析 (Graph)	PageRank / Louvain	GNN (GCN/GraphSAGE)	GraphRAG

深度学习在这些领域是扩展，而非替代。每一个亮起的橙色模块，都是支撑千亿美元产业的真实底座。

时序预测的现实引力：GBDT 的绝对胜利


Core Insight

真实时序信号多具有强阶跃结构（如促销突变）。GBDT 的轴对齐分裂天然契合，且训练成本仅为深度模型的 10^{-3} 。



实证判决：2020年 Walmart M5 销量预测大赛（5万亿条序列）。冠军方案是 LightGBM，所有带神经的深度模型全部败北。

永恒的数学直觉：Kalman 滤波与自适应权衡



历史与现代的映射

- 过去：1969年，驱动阿波罗登月导航的核心数学。
- 现在：这种预测与观测的自适应权衡思想，在 RL 的 Actor-Critic 到 LLM 的 RoPE 频率插值中不断重生。

50亿美元的协同过滤：推荐系统的矩阵骨架

TELEMETRY 

Amazon: 35% 销售额
Netflix: 80% 观看量
TikTok: 95%+ 流量分发

用户潜在因子矩阵 (U)

$$U \in \mathbb{R}^{|U| \times d}$$

预测未知的用户评分:

$$\hat{r}_{ui} = \mathbf{u}_u^T \mathbf{v}_i$$


物品潜在因子矩阵 (V)

$$V \in \mathbb{R}^{|I| \times d}$$


$$R \approx UV^T$$

历史节点：2009年 Netflix Prize
(100万美元赏金)。矩阵分解 (MF)
夺冠，从此成为工业界事实标准。

工业级推荐架构：多阶段漏斗流水线



干草堆里找针：孤立森林的几何智慧



异常点 (Anomaly) :
处于边缘, 仅需 1-2 刀
随机切割即可将其
完全孤立。

正常点 (Normal) :
极度密集, 需要横七竖八几十刀
才能将单个点剥离出来。

核心反直觉

不要试图对正常模式建模, 而是直接寻找最容易被孤立的点。

数学映射


路径长度 h 越短, 异常概率越高。

工业地位

金融欺诈与生产故障检测的 2024 工业标配。
极速且无需标签。

连接的引力场：PageRank 与图结构

关系性数据主宰世界：
社交网络、知识图谱、
分子结构。




$$PR(p_i) = \frac{1-d}{N} + d \sum \frac{PR(p_j)}{L(p_j)}$$

阻尼因子
(0.85)

邻居重要性的
加权聚合

1996 年，Larry Page 和 Sergey Brin 发明该算法，击败所有对手，成为现代 Google 的起点。

统计学的黑洞：高维空间的维度灾难



“


在 10,000 维的空间里，大家彼此之间的距离都是一样远的。

”

- 最近邻与最远邻的距离比趋近于 1。
- 直接在原始像素或 Token 上使用 KNN 或距离算法面临绝对物理失效。

降维与折纸隐喻：特征工程的绝对胜负手

流形假设 (Manifold Hypothesis)：
真实自然数据看似处于
极高维空间，但实际紧密
聚集在一个低维的褶皱
表面上。



Embedding 的本质：把
揉皱的纸摊平，在低维空
间中重建真实语义距离。

工业界真相

特征工程做完，模型选什么都差不多。Kaggle 大师们 80% 的时间在做特征构建（滞后特征、TF-IDF、目标编码），而不是调参。

不死的经典：被现代 AI 完整继承的数学骨架

经典骨架

推荐系统



现代 LLM 系统

RAG 架构



结论：RAG 本质上就是一个以 LLM 为排序器的推荐系统。



PageRank



Attention 机制

数学同构：PageRank 是网页图上的迭代聚合，Attention 是 Token 全连接图上的单步聚合。

双塔矩阵分解 (Dual-Tower MF)



向量检索 (Dense Retrieval / Sentence-BERT)


骨架不变，只是 Encoder 的函数容量变了。

真实世界的分工矩阵：LLM 与经典 ML 的边界互补

评估维度	经典 ML (GBDT/CF)	LLM (基础模型)
大规模实时性	千万级 QPS, <50ms 延迟 ✓	绝对失败 (延迟与成本过高) ✗
严格数值时序预测	极其精准 (轴对齐分裂) ✓	Token 采样导致数值漂移猜想 ✗
多模态特征提取	需数月人工标注 ✗	绝对统治 (秒级 Zero-shot 提取) ✓
冷启动语义先验	必须依赖 Bandit 探索积累 ✗	极强的 Zero-shot 先验估计 ✓

LLM 无法取代每秒处理 10^5 请求的 LightGBM 推荐内核。
但在解析非结构化特征时，LLM 能带来 10倍 的效能提升。

终局视野：LLM 时代的系统真实形态



经典底层：
时序 / 推荐 / 异常检测

编排层：
LLM 控制面板

不是替代，而是控制台

LLM 不是来取代你 5 年训练出的复杂工业推荐系统的。它是作为更高维度的接口与 workflow 编排层而存在的。



合作范式

LLM 提供更聪明的先验认知，经典算法处理高并发的探索与利用。



看透表象

学会在现代 AI 系统的华丽外衣下，识别出它正在跳动的、经典的数学心脏。

