


像素到特征：手工特征的天花板

为什么在深度学习爆发前的 30 年，人类一直在教计算机如何看世界？



特征决定上限，模型只是逼近上限。

• 人类视角 •


人类识别时间：< 1 秒



机制：依靠轮廓、纹理、先验经验瞬间脑补缺失信息。

• 机器视角 •

224 × 224 × 3 = 150,528 维无意义向量!




机制：直接输入离散数字引发维度灾难，毫无形状与语义可言。

洞察：在 15 万个无意义的数字与这是一只猫的概念之间，必须有一座桥梁——这座桥梁叫做「特征」。

统治 20 年的经典管线


2012年以前的绝对研究核心




原始像素
(15万维, 极度冗余)



特征提取器
(SIFT / HOG 等手工设计的数学公式)




编码器
(Bag-of-Visual-Words 化零为整)




分类器
(SVM / 随机森林)

学术共识：分类器选择已经是 Solved Problem。性能的差距，完全取决于人类设计特征的精妙程度。研究人员的全部精力都投入在如何寻找更好的数学表达式上。


SIFT: 尺度不变特征变换



① 极值检测 (DoG) : 寻找尺度空间突变点。



② 精确定位: 拟合 3D 二次函数, 剔除低对比度与边缘噪声。



③ 方向赋值: 决定主方向, 赋予特征极其强大的旋转不变性。




④ 描述符生成: 16x16 邻域切分, 输出最终的 128 维向量。




本质: SIFT 没有参数, 没有 Loss, 不依靠数据训练。它是人类关于「局部梯度结构极其稳定」这一先验知识的终极确定性数学表达。

HOG: 方向梯度直方图



设计哲学：放弃局部关键点，使用密集滑动窗口与梯度分布，来描述物体的整体全局轮廓。



历史印记：2005-2012年间自动驾驶与安防领域行人检测的绝对事实标准。被引用超过 **50,000** 次。


Safety Amber

诊断对比：两座大山的本质差异

	SIFT（尺度不变特征变换）	HOG（方向梯度直方图）
处理单位	稀疏的关键点（Sparse Keypoints）	密集的滑动窗口（Dense Windows）
输出形态	数量不定的 128 维向量组	单个固定的 3,780 维超高维向量
核心优势	极强的旋转与尺度不变性	出色的整体轮廓捕捉，线性计算极快
经典用途	图像配准、SLAM、三维重建	行人检测、人脸识别的全局分类

底部分析：无论局部还是全局，它们都在做同一件事——用严密的数学公式，人为定义什么图像信息是重要的，什么应该被丢弃。

跨越鸿沟: Bag-of-Visual-Words



(NLP)



(Computer Vision)



通过 BoVW, 视觉信号终于被转化为经典机器学习算法渴望的定长向量格式。

渐进退化实验：手工特征的脆弱性

Degradation Sequence



核心结论：人类极度鲁棒，因为我们能用过往的经验去填补缺失。而 SIFT/HOG 极度脆弱，因为它们只有冷冰冰的数学公式，面对真实世界的噪音毫无应对之力。

ImageNet 宇宙级复杂度 (1000类, 128万张图)

领域依赖

没有通用的手工特征。SIFT 认不出语音，HOG 看不懂医疗肿瘤。每换一个领域，人类就要重新发明一次轮子。

劳动密集

极度依赖天才直觉与算力试错。David Lowe 为了一篇 SIFT 论文耗费了整整 6 年的生命。

6 years

数学脆弱


极度依赖理想条件的数学假设。一旦实世界出现非刚性形变或复杂光照，算法立刻罢工。

$$I_s = \frac{d}{2\pi} M_{\omega, \phi_1}^2$$
$$\theta_k = \sum_{i=1}^n J_k \frac{\partial \mathcal{L}_k}{\partial \theta_k} (f(x, s))$$
$$\theta_k = \sum_{i=1}^n \frac{\partial \mathcal{L}_k}{\partial \theta_k} \frac{\partial \mathcal{L}_k}{\partial \theta_k} \frac{\partial \mathcal{L}_k}{\partial \theta_k}$$




人类手动推导公式的速度，永远跟不上真实世界物理复杂度的爆炸。

2012 崩塌之夜：ImageNet 悬崖




真相揭晓：特征被自动化，而非被否定

人类耗时几十年设计的数学结晶



Gabor Wavelets (经典边缘与方向滤波器)

深度神经网络训练一周自己学到的



AlexNet 第一层卷积 (Conv1) 滤波器

≈

“我们没有教它任何视觉知识，但它自己学出了和人类视觉皮层 V1 区极其相似的东西。

— Alex Krizhevsky


洞察：传统派和激进派都错了。SIFT 并没有死，它只是变成了 **CNN 的第一层**，被彻底参数化和自动化了。

优雅遗产：手工特征依然闪耀

SLAM / 视觉里程计

需要跨视角匹配的严谨数学
可解释性与几何保证。

ORB/SIFT 至今仍是 ORB-SLAM
系统不可替代的核心引擎。




边缘计算 / 嵌入式设备

面对极度受限的算力环境，树莓派上的 HOG + SVM 延迟极低，依然是轻量级实时监控的利器。




极端条件与分布外数据 (OOD)

面对未见过的恶劣场景，
冷酷的数学公式不会像
CNN 那样产生致命的
「过度自信」幻觉，
退化更为优雅和可预测。



图像配准与全景拼接

SIFT 与 RANSAC 算法的
几何一致性筛选天然契合，至今依然是 Open
CV 图像全景拼接框架
的默认配置。



工业界定律：在特定工程约束下，数学的绝对可解释性与极低算力消耗，常常压倒对极致精度的无休止追求。

跨时代同构：历史正在重演



核心暴击：「特征决定上限」的定律在今天依然绝对成立！底层的特征提取虽然被深度学习自动化了，但特征工程并没有消失，它只是被搬到了应用层。Prompt Engineering 就是 21 世纪的特征工程。

阴暗面：捷径学习与伪特征

Visual Evidence (视觉证据)



识别牛：热力图死死盯住草地背景



识别肿瘤：热力图高亮医院设备水印

Mathematical Mechanism (数学机制)

Shortcut Learning (捷径学习)



- 当黑盒全自动学习特征时，它追求的是纯粹的最大似然估计，而非真实的因果逻辑。 $P(\theta|D) \propto P(D|\theta)P(\theta)$



- 模型会不择手段地寻找最容易区分的统计捷径（如背景纹理、水印），完全忽略真实的物体形状。



延伸思考：这不仅仅是 CV 的问题。今天大模型（LLM）产生的所有幻觉和推理偏见，本质上都是 Shortcut Learning 在文本空间的幽灵复现。

终局沉淀与下一讲预告

全篇核心沉淀

1. 像素不是意义，特征才是桥梁：没有特征，数据就只是维度灾难。

2. 先验是捷径，也是天花板：人类把直觉变成公式，却永远追不上宇宙物理规律的复杂性。

$$P(\theta|D) = p(\theta|\theta) + \alpha \mathcal{L}(\theta|\theta)$$


3. 自动化取代手工业：深度学习没有推翻特征，而是将「什么是好特征」的选择权交给了反向传播。

$$P(\theta) = \frac{\partial f(\theta)}{\partial t - 1} \propto P\left(\frac{\partial \gamma(\theta)}{\partial r - i}\right)$$

既然特征不需要人写，
那机器到底该怎么自己学？

为什么随便叠一个网络不行，
非得是卷积神经网络（CNN）？

什么是局部性、平移不变性与
层级抽象？



下一讲引爆：
L07 卷积神经网络的崛起