




卷积神经网络（CNN）—— 把先验编码进结构

从 1962 年视觉皮层实验，到 2026 年多模态大模型的底层基因



128	64	32
0	-1	1
255	128	0






完全放手（纯全连接）

算力爆炸 (2.3×10^{10} 连接)
极易过拟合 / 无法收敛



半放手（The CNN Answer）

将人类对视觉的物理直觉，硬编码入网络拓扑结构




手工提取（特征工程）

SIFT & HOG
遇到表达力天花板 / 无法自适应

核心定理：归纳偏置（Inductive Bias）


模型在没有数据的情况下倾向于的解的集合。CNN 的胜利不在于它没有偏置，而在于它的结构偏置与真实物理世界的图像法则高度匹配。

1962 | Hubel-Wiesel
(诺贝尔奖)




简单细胞 → 复杂细胞

1980 | 福岛邦彦
(Neocognitron)



首创局部卷积与池化层级，
但缺乏反向传播算法。

1998 | Yann LeCun
(LeNet-5)



加入反向传播，实现美国
邮政局大规模商业部署。

诊断报告：为什么 90 年代 CNN 被卡住了？

数据封印

MNIST 太简单（6万张 28x28），
ImageNet 还要等整整十年。

算力封印

CPU 训练 LeNet 需一周。CUDA
和现代深度学习框架尚未诞生。


学术鄙视链

传统 SVM 拥有严密的 VC 维理论支持，
而 CNN 被主流视为不可解释的『炼金术』。

三大归纳偏置的物理学：把直觉变成数学

1. 局部性 (Locality)


直觉：重要的物理特征发生在相邻像素之间。



物理账单：暴力砍掉 >99% 的无用全连接。拒绝『左上角像素与右下角像素直接相关』的谬误。

2. 平移等变 (Translation Equivariance)

直觉：左上角的猫和右下角的猫，在语义上是同一只猫。




$$\text{Conv}(\text{Trans}(x)) = \text{Trans}(\text{Conv}(x))$$


物理账单：参数共享。一个 3x3 卷积核仅需 9 个参数即可扫描全图，极大降低过拟合风险。

3. 层级抽象 (Hierarchical Composition)

直觉：世界是组合的。
边缘 → 部件 → 整体物体。



物理账单：通过叠加多层卷积与下采样，感受野逐层呈指数级扩大，自动涌现高级语义。



破除认知神话：关于 Pooling 的真相



『Pooling (池化) 是 CNN 的本质』这是一个历史谬误。现代先进架构（如 ConvNeXt, EfficientNet v2）大量采用 Stride-Conv 彻底替代 Pooling。池化的真实物理作用仅仅是『空间降维』与提供局部的『平移容忍度 (Translation Tolerance)』，并非不可替代的魔法。

2012 ImageNet 大爆炸: AlexNet 的工程拼图

ReLU 激活




摒弃 Sigmoid 导致的深层梯度消失。
用极简的导数 1 拯救反向传播。

手写 CUDA 基建

```
__global__ void kernel(...)
{
    int tx = threadIdx.x;
    ...
    ...
}
```


在主流框架诞生前,以底层代码实现硬件级的算力榨取。

双 GTX 580 GPU (3GB 显存) | 6天极限训练




开启『算力兑换能力』的物理账单时代

Dropout 阵列



随机切断神经元,强行压制 6000 万参数面临的毁灭性过拟合。




数据增强 (Data Augmentation)



翻转、裁剪、PCA 颜色抖动,从有限数据中创造无限的训练变体。


『AlexNet 是工程的胜利,不是理论的胜利。它第一次把正确的组件正确地组合了起来。』

黄金时代 (2014-2019): 压榨参数使用效率的极致

架构理念	微型拓扑图	核心洞察	参数杠杆
VGG (2014) 极简深度		深度换感受野。三个 3x3 串联等效于一个 7x7，但参数量从 49 骤降至 27，且非线性更强。	极简标准化
Inception (2014) 宽度并行		引入 1x1 卷积作为跨通道降维与线性组合的核心武器。让网络『并行自我选择』最优感受野。	参数量仅为 VGG 的 1/12
EfficientNet (2019) 复合缩放		打破单一维度扩建的盲目性。推导 $d = \alpha^\varphi, w = \beta^\varphi, r = \gamma^\varphi$ ，实现深度、宽度、分辨率的严格数学联动。	同精度下最小参数


$$y = F(x) + x$$

视角 1: 梯度高速公路 (直观解剖)



给优化器留出绝对的『退路』。如果当前层无特征可学, $F(x)$ 将趋近于 0, 网络优雅地退化为恒等映射 (Identity Mapping)。这使得『加深网络』从一种高风险的梯度消失行为, 变为了零风险的无损变量。

视角 2: 子网络隐式集成 (进阶解剖, Veit 2016)



每一个 Skip Connection 本质上赋予了数据流『用或不用这一层』的二元选择权。一个 N 层的 ResNet, 实质上是 2^N 个不同深度的浅层子网络在数学上的宏大集成。

深远遗产: 没有这条极其简单的旁路导线, 今天 70B 到千亿参数的现代多模态大模型根本无法实现底层梯度的回传。

现代训练炼金术：决定生死的隐藏配方

SOTA = 架构创新 (30%) + 训练配方累积 (70%)

AdamW (2017)

解耦权重衰减 (Weight Decay)。让正则化在自适应学习率优化器中恢复正确的数学行为。



Mixup & Label Smoothing

打乱绝对自信。通过线性插值与软化标签，构筑防止深度网络过度拟合的正则化防线。



BatchNorm (2015) | 史上最重要的组件之一

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

抹平内部协变量偏移 (Internal Covariate Shift)。实现高达 10 倍的训练加速，彻底解放对学习率的敏感依赖。被引用超过 60,000 次的工程奇迹。




LayerNorm

抛弃 Batch 维度依赖，转而沿特征维度独立归一化。为未来 Transformer 处理不定长序列奠定标准配置。




He 初始化 (2015)

精确配平 ReLU 的『半激活』方差守恒。解决极深网络初始化时的信号湮灭。



第三幕危机：Vision Transformer (ViT) 的降维打击




L14 核心法则：规模反转架构偏置

在 ImageNet 级别，CNN 凭借『人类物理直觉』占据优势。但当数据规模到达亿级汪洋时，ViT 抛弃局部先验的『暴力美学』彻底释放。在绝对的数据规模面前，曾经提取特征的加速器，最终变成了限制模型表达上限的枷锁。


ConvNeXt 的反击：解开『架构与工程』的死结

变量控制与重构实验 (ConvNeXt 2022)



深层洞察：学术界大量标榜的『新架构革命』，剥开注意力机制的滤镜后，实际上是『现代训练 Pipeline』升级带来的红利。工程纪律与架构设计同等致命。


视觉大统一理论：同一个算子家族的权衡



没有不可解释的魔法。剥开各种华丽的架构外衣，所有的视觉神经网络本质上都是『Token Mixer + Channel Mixer』在空间与时间轴上的权衡落点。真正的范式转换屈指可数。


平移等变性的代价与位置感知

优势：完美的图像分类



CNN 天生不知道绝对位置，左侧的猫与右侧的猫完全等价。

代价：空间坐标的迷失



在目标检测 (Bounding Box) 与像素级分割中，极度缺乏位置感知能力。

殊途同归的重新发明



Transformer 并非抛弃了位置，它只是在用另一种数学形式，重新发明把位置信息编入等变算子的方法。

2026 视觉大盘格局：没有通吃，只有甜点区

多模态对齐

CLIP / SigLIP 统领。
ViT 居多，实现文本与
图像的统一空间编码。





超大预训练 / 生成模型

ViT / DiT 绝对统治。
在 JFT-3B 级数据海洋中，
规模致胜，零先验束缚。

边缘计算 / 极致效率

EfficientNet / ConvNeXt
称王。
在极低算力下，强归纳偏置
是不可替代的刚需。



工业部署 / 目标检测


Mask R-CNN (CNN
Backbone) 坚如磐石。
占据 60%+ 工业管线，
极度成熟稳定。

终极裁决：CNN 未死，ViT 未能通吃。
它们在各自的物理边界内共存，并无缝地互相借用工程代码。

多模态巨塔的底层基因：深度学习没有废弃的草稿


VISION TOWER (视觉巨塔)

Patch Embedding



剥开 Transformer 的外衣，它的入口本质上就是一个 $\text{Stride}=16$ 的超大核卷积。CNN 依然占据着大模型的第 0 层。

GELU 激活模块



AlexNet ReLU 路线的光滑化进化。半激活的方差守恒原理，依然在保护着千亿参数量的每一次更新。

$$x + \text{Attention}(\text{LN}(x))$$

残差网络的精确翻版。没有 2015 年 He Kaiming 铺设的这条旁路导线，现代 80 层以上的庞大模型根本无法反向传播梯度。

CNN 发现的物理法则与长达十年的工程沉淀，并未在历史中消亡。它们已经化为无意识的本能代码，沉默地运行在今天每一个最前沿多模态大模型的底层结构之中。