




语言智能的前世与暗骨



从词袋模型到序列标注——理解大模型时代前的 60 年 NLP 史

[ARCHIVE: 1954-2013] -> [RUNTIME: 2026]

自然语言处理的“第零号问题”：如何将离散的符号转化为数学对象



145	210	0	78
78	192	255	30
78	192	192	255
100	50	50	30



计算机视觉：天然的连续数学对象

RGB 像素矩阵直接映射为 $[0, 255]$ 的具体数值。

银行



银行 $\neq 0.7$


银行 $\neq [0.3, 0.8]$

自然语言处理：离散符号的黑盒

文字是脱离连续数值的离散符号，无法直接进行代数运算。⚠


文本表示的演化阶梯： 长达半个世纪的统计学极限攀爬

BoW 词袋模型 (1950s-70s)




文档退化为纯粹的词频计数向量，彻底失去语序排列。

N-gram 语言模型 (1980s)




通过马尔可夫近似捕捉局部语序。**GPT** 的原始形态，受困于指数级的数据稀疏性。

TF-IDF (1972)




引入**全局权重**，自动识别词汇区分度，过滤停用词。

BM25 (1994)




工业级变体。引入长度惩罚与词频饱和修正，至今仍是**检索基线**。

机制解剖：TF-IDF 与 BM25 的代数本质




「**核心机制**：自动对抗高频停用词。“的”极重但烂大街权重极低；“量子”罕见从而获得极高区分度权重。」



[2026 工业快照]

Elasticsearch 默认基线。现代 RAG 系统的 Hybrid Search 标配 (BM25 稀疏检索 50% + 稠密向量检索 50%)。


序列的统治者：隐马尔可夫模型（HMM）与 Viterbi 解码



三十年统治：1980s 语音识别核心 → 2011 Siri 初代引擎 → 如今序列状态机思想的先驱。

判别式的胜利：条件随机场（CRF）的全局视野

HMM (生成式 / 局部归一化)



「建模 $P(X, Z)$ 。受限于严苛的独立性假设，视线被阻断，容易产生局部最优偏倚。」

CRF (判别式 / 全局归一化)





「建模 $P(Z|X)$ 。无独立性约束，利用复杂的全局特征函数纵览整个上下文。」

CRF 没有被深度学习杀死，而是被包围了。

BERT (特征提取，提供上下文向量) + CRF (最后一层合法性约束) = 现代 NER 工业首选架构

分词器的演进：大语言模型真正的零号问题



BPE 贪心压缩本质：不是寻找语言学上的词，而是在固定词表大小 K 约束下的最小描述长度 (MDL) 求解。




隐藏的性能瓶颈：Tokenizer 直接决定了模型的参数量、推理效率以及多语言公平性（中英真实容量差异可达 2-3 倍）。



共同天花板：只要将词汇视为离散符号，语义就永远无法计算


古典死胡同 (The Classical Dead End)



在 BoW/TF-IDF 空间里，“King”与“Queen”是绝对正交的孤立符号，余弦相似度恒为 0，毫无语义交集。

连续未来 (The Continuous Future - Preview)


$$\text{King}\vec{n} - \text{Man}\vec{n} + \text{Woman}\vec{n} \approx \text{Queen}\vec{n}$$



范式断点：从离散符号匹配转向连续空间中的向量代数运算，是进入 Word2Vec 与大模型时代的逻辑必然。


2026 架构透视：经典算法并未消亡，而是化作隐形骨架

X-Ray Architecture Map




尾声：我们用极致的语义能力，换取了绝对的可解释性

The Trade-off Diagnostic



经典 TF-IDF：特征独立，每一维的意义人类完全可知。



现代大模型 Embedding：能力跃升，但彻底沦为不透明的黑盒浮点数。

The Terminal Conclusion

- > 经典 NLP 不是被时代抛弃的失败者，
- > 而是人类 60 年算法智慧的结晶。
- > 它们让出了 AI 的视觉中心，
- > 转入了工程架构的隐秘边缘。
- > 但在真实世界的生产系统中，
- > 边缘，从未如此重要。

