




从 RNN 到 Attention: 序列与记忆的架构进化


深度学习如何跨越梯度死局与信息瓶颈，最终重塑语言计算的本质

L10 架构解析图谱 //
基于 2026 LLM 前沿视角重构

语言的非局部诅咒与时间先验


CNN 赋予视觉以结构，但语言的本质是序列。远距离依赖跨越从句与修饰语，局部感受野（如 3×3 卷积）在此失效。网络必须引入将时间顺序编码进结构的归纳偏置。

空间局部性归纳偏置




局限于相邻像素

语言的远距离依赖



RNN 范式：参数共享与逐步压缩



$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b)$$


直觉隐喻：读书写摘要

阅读小说时，你不会记住所有字词，而是在脑中维护一个不断更新的摘要（隐状态 h_t ）。

架构先验

- 1) 时间顺序决定输出；
- 2) 相同处理逻辑（ W ）适用于每个时间步。

传话游戏与指数级毁灭：梯度消失的数学根源



数学根源


$$\frac{\partial L}{\partial h_1} \approx (W_{hh}^T)^{T-1} \frac{\partial L}{\partial h_T}$$

$$0.9^{100} \approx 2.7 \times 10^{-5}$$

核心结论

1994 年 Bengio 等人证明：连乘导致梯度随时间步指数衰减。RNN 实际上只能记住 10-20 步信息。

LSTM 的破局：用加法修建梯度高速公路



$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

核心创新

乘法变加法。避免了 W 的连乘，只要门控开启，梯度无损直达起点。

笔记本隐喻


赋予网络一个可选择性写入和擦的笔记本，记忆不再随时间强制衰减。

历史互文

LSTM 的加法残差思想，比 ResNet ($F(x) + x$) 早了整整 18 年。

Seq2Seq 架构标准与物理隐患

2014年成为机器翻译工业标准，但内置了架构级致命缺陷——所有信息必须被强行压入固定长度的向量中。短句完美，长句崩溃。



绝境：信息论视角的必然坍塌

Tishby 瓶颈定理：

$$I(\mathbf{c}; \text{output}) \leq H(\mathbf{c}) \leq d \log_2 |\text{vocabulary}|$$



无论如何调参，物理管道的宽度死死锁住了任务的理论上限。长句信息熵远超浮点表示极限。


仿生学发问：

人类在做翻译时，真的会闭眼读完一整本书，然后再开始凭记忆默写吗？


范式革命：放弃压缩，随时回头检索

Attention 带来了架构哲学的转变：不再将所有信息压缩成一个死寂的向量，而是动态聚焦历史的最相关部分。

架构机制 (The Mechanism)




历史 artifact: 1994 对齐矩阵可视化 (Alignment Matrix)



核心引擎：Attention 三步流转公式

核心伏笔：这是后续 QKV 机制的前传 —— 用 Query 匹配 Key，最终提取 Value。




降维打击：Attention 本质是可学习的 Soft k-NN

维度	Hard k-NN (传统机器学习)	Attention (Soft k-NN)
距离度量	L2 欧氏距离	可学习的内积/相似度 $\left(\frac{\langle q, k_i \rangle}{\sqrt{d}}\right)$
选择机制	Top- k 离散截断	全局 Softmax 连续概率分布
输出计算	k 个邻居的多数表决 / 平均	所有邻居 Value 的加权求和


大模型视角的降维理解：Attention 并非魔法，它是在高维连续空间中执行的一次软性信息检索。距离是可学习的，检索是完全可微的。

澄清迷思：注意力权重 $\neq$ 模型解释

迷思 (The Myth)




现实 (The Reality)



- 依据 Jain & Wallace (2019) 严格论证：权重分布与模型最终决策的因果关联极其微弱。
- 高亮的热力图对齐更多是模型生成的『事后合理化』(Post-hoc rationalization)。
- 切勿将 Attention 分布过度解读为模型的思维过程本身。


序列建模范式：全维度诊断矩阵

横跨四大基础架构的核心特征收敛视角

	RNN	LSTM	Seq2Seq	Attention
记忆模式	默记摘要 	笔记读写 	固定漏斗 压缩 	全局并行检索 
信息流动	乘法连乘 	加法残差 	瓶颈截断 	绕过瓶颈直连 
长程能力	10-20 步 	约 1000 步 	随长度迅速衰减 	理论无损 
容量上限	固定 	固定 	固定 (d 维) 	随序列动态增长 (T·d 维) 


2026 现实校准：RNN 并没有死，它学会了并行

Transformer 当年取代 RNN 的根本工程原因不是更准，而是去除了串行依赖，实现了极致的硬件并行。



历史正在螺旋式上升。

终极追问：如果彻底抛弃『时间』？



Attention 完美解决了长距离记忆问题，但 RNN 的串行躯壳依然锁死了模型的训练速度极值。
故意问题：如果我们干脆扔掉 RNN 躯壳，只用 Attention，让序列中所有位置在同一瞬间看到彼此，这甚至合理吗？

敬请期待 L12: Transformer 革命与向量空间的统治。