



把意义变成几何

离散符号时代的终结，与多模态通用语言的诞生



向量算术揭示的语义奇迹


2013年，Word2Vec 模型在没有任何硬编码规则的情况下，偶然在连续空间中展现出令人震撼的几何性质：意义可以进行加减运算。



停滞六十年的困境：维度灾难与语义失明


维度灾难 (The Curse of Dimensionality)

如果词表有十万词，使用 One-Hot 编码意味着每个词都是十万维的稀疏矩阵，导致灾难性的计算与存储开销。



语义失明 (Semantic Blindness)

任何两个不同词的距离完全相等，系统对语义彻底失明。




$$\begin{aligned}\text{cosine}(\text{猫}, \text{狗}) &= 0 \\ \text{cosine}(\text{猫}, \text{经济学}) &= 0\end{aligned}$$

上下文即意义本身

You shall know a word by the company it keeps.


— J.R. Firth, 1957

一个词没有孤立的内在意义。如果两个符号被相同的上下文云包围，它们在几何空间中必然被映射到相近的位置。




空间造物引擎：引力与斥力的博弈

无需遍历十万词表。每一次训练，只需拉近真实的上下文邻居，并推开少量的随机负永样本，整个高维空间的几何秩序便会自然涌现。



神话解构

Word2Vec 的训练目标，在数学上等价于对点间互信息 (PMI) 矩阵进行隐式分解。向量算术并非魔法，而是统计规律在对数空间中的必然映射。



几何法则的显影


差向量代表的是「皇家 (royalty)」与「平民 (ordinary)」这两个抽象概念,在浩瀚训练语料中的协变 (Covariant)。



$$\mathbf{v}_{\text{King}} - \mathbf{v}_{\text{Man}} \approx \log \frac{P(\text{King}|\text{royalty})}{P(\text{Man}|\text{ordinary})}$$



空间法则：如何在星图中测量距离

余弦相似度 (Cosine)	点积 (Dot Product)	欧氏距离 (Euclidean)
		
物理意义：只看方向夹角，完全忽略向量的绝对长度。 应用场景：NLP 标准配置。无论模长如何，方向对即为相似。	物理意义：方向一致性 $\times$ 绝对模长。 应用场景：Transformer 注意力机制。模长隐式编码了信息的重要性。	物理意义：高维空间中两点之间的绝对直线距离。 应用场景：K-Means 等传统聚类算法。

构建星系的成本：维度收益与降维观测


维度边际递减法则

从300维提升至1000维，模型性能差距不到2%，但显存消耗翻了3倍。更高维度并不总是更好。



高维观测 (t-SNE/UMAP)

降维算法仅用于人类视觉观测，其簇大小与间距缺乏绝对几何意义，不可用于下游计算。



宇宙大一统：跨越模态的巴别塔

向量空间是多模态的通用语言。所有原始数据形态灰飞烟灭，
最终在同一个高维维度里化为只受余弦相似度支配的点。




统一向量空间
(Shared Vector Space)

对齐万物：CLIP 与跨模态的握手

2021年，OpenAI 彻底打通图文孤岛，通过四亿组数据的对比学习，构筑了多模态大模型的底层基石。

正样本配对（互相拉近）



[文本] 一只金毛在奔跑

负样本排斥（互相推远）



[文本] 一辆红色的汽车

工业级星际导航：绕过维度的诅咒


在拥有十亿级节点的空间中，寻找最近邻的精确遍历会导致系统瘫痪。算法牺牲微小精度，换取万倍速度。

分层小世界图（HNSW 算法）

第一层：稀疏高速公路

第二层：中等密度导航

底层：密集数据星海



暴力搜索
 $O(N \cdot d)$

HNSW 近似搜索
 $O(\log N)$


基础设施生态：向量检索引擎选型

HNSW + PQ 已成为 2024+ 向量数据库的事实标准。工程师的核心调优精力将集中在索引参数上。




大一统接口：Embedding 作为大模型通用协议

训练目标只是手段，产生高质量的 Embedding 才是真正产品。LLM 时代所有的理解与交互，全建立在这条向量总线之上。




空间破缺：被扭曲的星图与语义偏见

几何模型无情地编码了人类历史训练数据中的社会偏见。修复偏见意味着重塑空间的拓扑结构。



坍塌的静态宇宙：多义词的撕裂与时空的呼唤

因为静态模型只能分配固定坐标，多义词被迫停留在互不相干的星云中间的真空地带（混合平均的谬误）。



如果让词的向量根据上下文动态游走，瞬间纵览全图，模型该是什么形态？

➡ 下一讲：时间与注意力的降临 —— Transformer