



Transformer: AI时代的通用引擎

Attention Is All You Need (2017) —— 从黑盒到透明矩阵的解剖学之旅



告别先验：为什么 RNN 必须死？

串行计算是对 GPU 算力的最大亵渎。Transformer 的核心承诺是：让所有位置直接互相倾听。


维度	RNN	CNN (1D)	Transformer
并行计算能力	✗ 串行（完全浪费GPU）	✓ 局部并行	✓✓ 极高（全局并行）
任意两点路径长度	$O(n)$ （长程信号剧烈衰减）	$O(\log n)$	$O(1)$ （一步直达）
单层计算复杂度	$O(n d^2)$	$O(k n d^2)$	$O(n^2 d)$ （致命代价）

重塑直觉：图书馆里的 Self-Attention



分离 Q 和 K 是关键——“匹配度高” (Key) 并不意味着“输出本身” (Value)。
这是 Attention 与普通加权平均的根本区别。

引擎的心脏：主宰 LLM 的单行公式



点积衡量相似度。全程
矩阵乘法，完全可并行。


归一化为概率分布。



$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

CORE EQUATION

TENSOR OPS




防止梯度消失的数学必然。
不缩放会导致方差激增至 d_k ，
Softmax 饱和，梯度彻底归零。

基于概率分布的
加权信息提取。



多头机制：多重视角与现实的冗余

理论期望




实测真相



“多头多视角”更多是教学比喻。真实世界的冗余直接催生了后来的 MQA 与 GQA，成为 Llama 的事实标准。

位置编码：突破“集合”的诅咒

没有位置编码，Transformer 只是一个无序的 Set Processor。“狗咬人” = “人咬狗”。




Sinusoidal (2017)

正弦/余弦固定向量（绝对位置，加法）



Learned PE

可学习向量（绝对位置，加法）



RoPE (当代主流 Llama)

旋转矩阵（相对位置，乘法）。人类句法本质是相对的，因此 RoPE 一统江湖。




ALiBi / YaRN

长文本外推与频率插值

细胞结构：Transformer Block 的层叠奇迹

Residual Connection (残差) :
给优化器留下的跳跃高速公路。




先升维 4 倍再降回。占据约 2/3 的参数量，真正的“知识记忆体”。

路由与信息检索机制。

Pre-LN 保证了残差路径干净，是今天能够堆叠 100+ 层（如 GPT-3/Llama 3）的硬性工程前提。


三分天下：范式大分流与 Decoder 的胜利

Encoder-Only (如 BERT)



全向互看矩阵（无遮挡）。
适合：分类、填空、理解。


Decoder-Only (如 GPT, Llama)



$$\text{Mask}[i, j] = 0 \text{ if } j > i \text{ else } 1$$

因果掩码矩阵（Causal Mask）。
只能看过去，不能看未来。

Encoder-Decoder (如 T5, Whisper)



非对称架构。
适合：翻译、语音转录。

Decoder-Only 天然适配自回归生成，享有无与伦比的规模缩放优势（Scaling Law），最终在 2020 年后垄断大模型架构。

推理的魔法：KV Cache 与非参数化状态空间

Naive 计算 (复杂度 $O(n^3)$ - 慢得无法商用)



每步生成都需重新计算所有历史Token的KV值，计算量随序列长度立方级增长。

KV Cache 计算 (单步 $O(n)$ - 速度提升千倍)



仅计算最新Token的KV值并追加到显存缓存区，历史信息被冻结，实现极速推理。

本质上，推理时的 Transformer 变成了一个显存线性增长的 RNN。速度的代价是：推理成本从算力瓶颈转移到了显存瓶颈。

物理账单： $O(n^2)$ 的死亡曲线

Attention 矩阵显存消耗 (基于 FP16)

“长上下文不是算力问题，它是撞上了一堵 $O(n^2)$ 的记忆墙 (Memory Wall)。”

32K → 2 GB


128K → 32 GB
(单卡红色警戒线)

1M → 2 TB
(彻底崩溃 / 不可行)

Context Window (Token 上下文长度)


突围之战：解救记忆墙的现代药方

FlashAttention (硬件级手术)




规避 GPU 显存读写瓶颈，通过 Tiling 在 SRAM 内部切块解决。速度翻倍，显存暴降。

GQA / MQA (架构级压缩)




压缩 Key 和 Value 的注意力头数量，强行将 KV Cache 的体积缩小 85% 左右。长文本成为可能。

Mamba / SSM (颠覆级异端)



放弃 Attention 公式，用状态空间模型做到真正的 $O(n)$ 线性复杂度。未来混合架构的先驱。

万物通天塔：通用性的彻底胜利



结语：规模战胜先验

Transformer 不是更聪明的算法。它是对输入假设最少、对硬件最友好的极端工程胜利。归纳偏置的精巧巧路线，最终输给了暴力的规模路线。]

下一讲预告：第 13 讲 - 【BERT vs GPT】

同样的引擎架构，为什么“续写”最终打败了“填空”？
预测下一个词，为何在数学上等价于理解世界？