



同一个 Transformer 架构如何分化出两种截然不同的智能哲学




2018 年，Transformer 架构的横空出世解决了一切问题，却也留下了一个根本的悬念：
我们究竟应该用这把完美的锤子去敲打什么目标？

2018 年 NLP 领域的终极困境与预训练的破晓



历史性抉择：当底座统一为 Transformer 后，预训练的数学目标究竟该如何设定？


BERT: 看完全文再填空的双向学者



架构:	Encoder-only
核心目标:	Masked Language Modeling (MLM)
机制:	随机遮蔽 15% 的 token 并预测全貌。
细节设定:	80% 替换为 [MASK], 10% 随机词, 10% 保持不变。

2018-2020 统治级表现: GLUE 跑分跃升至 82.1, 11 项 benchmark 刷新 SOTA。

GPT: 只能凝视过去并预测未来的自回归先知




架构:	Decoder-only
核心目标:	Autoregressive Generation
数学表达:	$P(x_1, \dots, x_n) = \prod_n P(x_t x_1, \dots, x_{t-1})$
核心哲学:	联合概率分解为条件概率的乘积。每一步基于过去预测未来。

2018 年的共识错觉: GPT-1 单向的严苛限制在静态基准测试中全面落败于 BERT。


GPT-2 的 Zero-Shot 顿悟：重构人机交互范式

BERT 范式



任务知识存在于特定的网络头部。每一个任务都需要独立的标注数据与微调流程。

GPT-2 范式




任务知识存在于自然语言提示词中。1.5B 参数的涌现带来了 Zero-shot 能力，无需任何微调。

隐藏在底层的算账：为什么规模扩展放大了 BERT 的劣势


BERT 训练效率

信号密度：15% ($0.15 \log V$ bits)



GPT 训练效率

信号密度：100% ($1.0 \log V$ bits)



对比维度	BERT（双向掩码）	GPT（单向自回归）
生成能力	无法按顺序连贯生成	逐 token 高效采样
任务通用性	需要重新设计 Task Head	Prompt 描述任意任务
数据效率	同等 FLOPs 下提取知识极少	每一次预测都产生全局梯度，复利扩大

同样规模的算力投入下，自回归模型榨取了训练语料中每一个 token 的信息。


Shannon 等价性：最优的预测在数学上等同于最优的压缩



Claude Shannon (1948)

$$H(P, Q) = -\sum P(x) \log Q(x)$$


Next-Token Prediction



核心洞察：预测下一个词绝非简单的统计学拟合。要在信息论层面上完美预测序列，模型就必须完美压缩世界知识。


降低交叉熵损失（CE Loss）的过程，本质上就是模型在疯狂压缩人类几千年积累规律的过程。

预测 = 压缩 = 理解：世界规律被隐式编码进神经网络权重



实证支持：DeepMind (2024) 证明 Llama 作为通用压缩器，在文本压缩上超越 gzip，图像超越 PNG，音频超越 FLAC。

In-Context Learning (ICL): 自回归目标带来的超快隐式微调



自回归的本能

自回归预测自然要求序列模式续写。当给出任务示例时，GPT 会在数学上延续这种序列内部的转移规律，实现零样本泛化。

BERT 的致命死穴

填空目标只要求局部上下文补全，并不强求模型学习整个序列的动态模式转移，因此彻底无缘 ICL 能力。

T5 的命运：思想一统江湖，架构却走向消亡



设计说明

T5 证明了所有任务都可以抽象为文本到文本的转换。然而，GPT-3 以更经济的方式赢得了这场战争：Prompt 直接充当了虚拟的 Encoder。庞大的参数无需被分割，同时为理解与生成服务，彻底淘汰了繁冗的 Encoder-Decoder 双体架构。

隐藏的胜负手：RLHF 与 Decoder-Only 架构的天然契合



BERT 的死穴

BERT 的死穴：要实现基于人类偏好的强化学习对齐，模型必须能够生成完整的动作序列并接受奖励计算。Masked 填空机制无法被转化为连贯的策略动作序列，从数学根源上断绝了引入 RL 算法对齐人类意图的可能性。

■ 文本压缩的物理边界：什么知识是无法被纯文本预测出来的？

Cognitive Boundary Matrix

知识类型 (Understanding Type)	单纯文本预测的 可行性	根本限制缘由
事实知识、句法与浅层演绎	完全掌握 (■)	规律完整暴露并内含于千亿词汇的语料库中。
多步逻辑、因果推理与时空几何	勉强模拟 (■)	文本仅提供相关性，缺乏对物理世界结构的精确空间与干预表征，需依赖 CoT 展开。
物理行动控制与主观体验 (Qualia)	不可逾越 (■)	塞尔的中文房间悖论。缺乏 Motor Command 与具身传感，单纯扩大参数规模无法凭空涌现多模态物理交互。

Shannon 等价性仅在文本能编码的知识范畴内严格成立。

2026 演化生态图谱：编码器已死是对技术生态的严重误读

通用生成式智能体
(Frontier Generative Agents)

活人地区：
GPT-5, Claude 4,
Llama 4, DeepSeek-V3

100% Decoder-Only 生态圈

高并发检索与表征底座
(High-Efficiency Retrieval Backends)

活人地址：
ModernBERT, BGE-M3

Encoder-Only 统治区

BERT 并没有被淘汰，而是完成了战术撤退。高并发的 RAG 检索后端、密集向量表征 (Dense Embeddings) 和极低延迟分类任务依然是其无可争议的领地。两条历史分叉路线最终在生产环境中走向了完美互补。

终局启示：架构仅仅是躯壳，评判者 (Evaluator) 定义了智能的最终形态

可验证器 (Verifier / System 2)

评判标准：逻辑链路是否可通过程序严格验证？

→ 塑造能力：深层数学与数理逻辑推理。

奖励模型

(Reward Modeling - RLHF)

评判标准：人类是否偏好这个回答？

→ 塑造能力：无害性与极致指令遵循。

交叉熵损失

(Cross-Entropy Loss)

评判标准：像不像语料中的下一个词？

→ 塑造能力：世界知识压缩与常识生成。



BERT 与 GPT 的架构之战，本质上是关于数据效率和对齐潜力的代理人战争。同一个基础模型躯壳，接入不同的评判者，最终会长出截然不同的智能树干。