


核心启示：AI 不再是炼金术

OpenAI 在投入 1 亿美元训练 GPT-4 之前，用极小规模模型准确预测了它的最终表现。

外推的奇迹：仅仅使用了 GPT-4 万分之一（1/10,000）的算力进行微型模型实验。

物理学视角的转换：训练超级 AI 从盲目的“科学猜想”变成了精准的“资源分配问题”。


你花多少钱，就能买到多少能力。



Kaplan 的发现：主宰智能的三组幂律

Johns Hopkins 理论物理学家将研究黑洞的方法引入了 AI 领域。在对数-对数 (log-log) 坐标下，复杂的神经网络表现为完美的匀速直线。


算力 (Compute)



$$L(C) \propto C^{-0.050}$$

每将浮点运算增加 10 倍，Loss 下降固定百分比。


参数 (Parameters)



$$L(N) \propto N^{-0.076}$$

模型扩大 10 倍，能力提升比例恒定。

数据 (Data)



$$L(D) \propto D^{-0.095}$$

增加训练 Token 数据，模型持续进化。

进步越来越难，但收益永不为零。

进化的架构：GPT 系列的资源核算

GPT-1 (2019)
参数 1.5B | 数据 40GB
算力 $\sim 10^{18}$

高显眼橙色标签：成本 \$1M

GPT-1 (2018)
参数 117M | 数据 4.5GB
算力 $\sim 10^{16}$

高显眼橙色标签：成本 < \$100k

GPT-3 (2020)
参数 175B
数据 300B
算力 $\sim 3.1 \times 10^{23}$

高显眼橙色标签：成本 \$5-12M

GPT-2 (2019)
参数 1.5B | 数据 40GB
算力 $\sim 10^{20}$

高显眼橙色标签：成本 \$1-5M

GPT-4 (2023)
参数 $\sim 1.8T$
数据 $\sim 13T$
算力 $\sim 2 \times 10^{25}$

高显眼橙色标签：成本 \$60-100M

GPT-1 到 GPT-4 算力暴涨 2,000 万倍。
GPT-3 并非拍脑袋的产物，它是特定算力预算下，曲线上唯一的数学最优点。

Chinchilla 修正：打破“参数为王”的迷思

Kaplan 曾建议优先扩大模型参数。DeepMind 测试了 400 个模型后发现：数据量和参数量必须等比例增长。

$$N_{\text{opt}} \propto C^{0.5}, D_{\text{opt}} \propto C^{0.5}$$

最优的法则：Chinchilla



最优的配比：1 个参数对应 20 个 Tokens。
规模不仅需要大，更需要正确的比例。

商业化倒逼：Inference-Optimal 的诞生

如果你的模型每天要被调用数百万次，为训练算力优化不再是最优解，你需要为推理运营成本（Opex）优化。



在训练阶段投入巨资“过度训练”，换取更小、更聪明的模型，从而在每天的推理运行中节约海量成本。

“涌现”争议：是智能觉醒，还是测量伪影？



非连续指标 (Exact Match)
突变假象 (Mirage of Emergence)

完全答对才给分，当模型跨过阈值的瞬间表现为突然觉醒。



连续指标 (Log-loss)
真实的渐进 (Smooth Progression)

换成 Token 级准确率后，进步始终是平滑且可预测的。

Schaeffer 的证明： Scaling Law 买到的是渐进的基础能力提升，而不是随机突变的魔术。
所谓的突变，往往是我们手中度量尺过于粗糙。

第一根轴的盲区：Loss 下降的局限

Scaling Law 指向的是一个统计学事实：平均 Loss 的必然下降。
但平均值的下降并不保证特定知识结构的建立。

Scaling 指数
 $\alpha \approx 0.05-0.10$

隐藏的盲区
(如复杂数学、逻辑推理)

GPT-4 在某些特定数学任务上甚至可能弱于 GPT-3.5。纯靠规模扩展 (Pre-training) 可以买到强大的“直觉”和知识库，但无法直接买到严密的“系统 2 推理 (System 2 Thinking)”。

三面墙：接近规模扩展的物理极限



纯靠第一根规模轴（训练扩展）通向 AGI 的路径，正面临天文数字般的物理与资本阻力。

破局点：第二根规模轴（Inference-Time Scaling）

2024 年 o1 与 R1 范式证实——在推理时给模型更多“思考时间”，能力提升同样遵循幂律，且斜率更陡！

Y 轴：推理时间算力
Inference Compute

⚠ 物理极限
Physical Limits

$$\text{Performance} \propto N_{\text{infer}}^{\beta}$$

X 轴：预训练算力
Training Compute

1. 停止盲目增大模型体积，转而**延长思维链（Chain-of-Thought）**与**多路径采样**。
2. 从“巨大的模型 + 瞬间的回答”转向“**更小的模型 + 深度的思考**”。
3. 当训练扩展撞墙时，**推理扩展接力跑**。算力预算越多，智能越高。

双轴策略矩阵：参数扩展 vs. 思考扩展

AI 的竞争前沿已从纯粹的资本密集型预训练，转移到了算法密集的推理期寻优。

	第一轴：训练时扩展	第二轴：推理时扩展
消耗资源 (Resource)	 参数量、训练数据	 推理 Token 数、 搜索树深度
扩展效率 (Exponent)	 收益较缓 ($\alpha \approx 0.05-0.10$)	 特定区间收益更陡峭 ($\beta \approx 0.20-0.40$)
核心瓶颈 (Limits)	 语料耗尽、能源墙	 验证器质量 (Verifier Quality)、 奖励模型上限
经济形态 (Economics)	 极端的资本支出 (Capex)	 随使用量线性增长的运营成本 (Opex)

2026 年的物理账单：GPT-5 级别的经济学

AGI 前沿设施采购清单

项目 01：模型预训练单次成本
~ \$ 1,000,000,000.00 +

项目 02：底层硬件基础设施
~ 2,000,000 顶级 GPU 阵列
(单体集群估值 \$5,000,000,000)

项目 03：能源基建 (核电 PPA 协议)
~ \$ 10,000,000,000.00 / 节点

花多少钱买多少能力的定律依然有效，只是账单的单位从千万美元跃升到了百亿美元。前沿模型将不可避免地集中在 3-5 家超级公司手中。中型玩家唯一的突围路径是拥抱推理时扩展 (Inference-Time Scaling)。

总结：未来 5 年 AI 进化的预测蓝图

要预测 AI 的未来，不要看炒作的营销话术，请直接去查看算力的供应链、能源的消耗曲线和 Token 的账单。物理学和经济学，才是 AGI 最真实的底色。



资本预算 (Capital Budget)

芯片产能和核电规划
划定了 AGI 的硬性边界

规模法则 (Scaling Laws)

能力提升非随机涌现，
而是遵循可测算的幂律

模型架构 (Optimal Ratios)

遵循 Chinchilla 平衡，
或为推理成本极度优化

第二轴加速 (Inference Scaling)

训练撞墙时，用算力换
取推理期的长思考

智能 (Intelligence)

解锁高级逻辑系统