


性格工程：让强大的模型变得有用

从预训练的“世界知识”到对齐的“行为规范”——探索大模型性格塑造的工程与哲学。



原始知识不等于有用性

预训练赋予了模型海量的世界知识，但没有教会它如何与人类互动。未经对齐的模型就像一个读过世界上所有有书的野生天才——他知道莎士比亚，也知道量子力学，但他根本不听指令。



世界知识

175B 参数，无序



行为规范

1.3B 参数，定向

行为比知识更重要。对齐让 100× 小模型变得更有用。

野生的天才 vs 社会化的助手

同一个拥有 70 亿参数的大脑，同样的训练数据。唯一的区别在于输出分布的改变——从“文本续写机器”变成了“对话助手”。

Prompt: 如何向一个 6 岁的孩子解释引力？

未驯化 (Base Model) – 续写模式

如何向一个 8 岁的孩子解释黑洞？如何向一个 10 岁的孩子解释相对论？如何向一个 5 岁的孩子解释量子力学？如何向一个...

模型没有回答，而是在续写相似的问题。

已对齐 (Instruct Model) – 对话模式


想象你拿着一个很重的保龄球站在蹦床上，蹦床会往下凹陷。如果你往蹦床上滚一颗小玻璃球，它会向保龄球滚过去。引力就像是宇宙中的大蹦床...

模型理解了意图，给出了结构化的回答。

ChatGPT 的基石：RLHF 三步流水线

对齐不是一步到位的，InstructGPT 确立了将“人类偏好”转化为“可学习奖励信号”的标准流程。

Step 1: SFT (监督微调) Step 2: RM (奖励模型) Step 3: PPO (策略优化)



教模型“听人话”。人工编写初始数据，将模型从续写模式切换到对话模式。

将人类品味“数字化”。通过人类标注员的排序数据，训练神经网络来打分。

在奖励指引下调整行为。通过强化学习让模型生成能拿 RM 高分的回答。

PPO 的数学平衡：讨好裁判与保持自我

在强化学习阶段，模型极易陷入局部最优——为了获得高分而彻底丧失原有的世界知识。

$$Reward = r(x, y) - \beta * KL(\pi_{new} \parallel \pi_{SFT})$$

追求 RM 高分

追求 RM 高分

讨好 RM（可能导致
Reward Hacking，
输出冗长空洞的
废话以刷分）



KL 惩罚项

约束偏离度（防止
模型忘记预训练知
识，变成只会附和
的复读机）



β

β

$\beta \in [0.01, 0.5]$ 是天平的游码。没有 KL 约束，模型会完全坍缩；约束太强，模型学不会对话。对齐税的数学根源就在这里。

DPO 革命：降维打击的数学之美

RLHF 需要同时维护 4 个模型且极度不稳定。2023 年，DPO（直接偏好优化）通过数学等价证明，彻底消除了 Reward Model 的中间环节。



工程复杂度降低 10 倍。直接促成了 Llama / Mistral / Qwen 等开源模型的对齐爆发。

2026 实务选型：对齐工程工具箱

没有绝对“最强”的方法，DPO 家族的每一个变体都是对特定工程痛点的权衡。按数据特征和任务类型选用。



Constitutional AI: 让大模型自己约束自己

将“对齐知识”从黑盒般的奖励模型权重中剥离，转化为显式、可读、可审计的文本规则（宪法）。



核心转变：这一步将价值观从隐式权重变成了可版本化、可多语言翻译的显式 Markdown 文本。

对齐的本质：是教育，还是驯化？

对齐不是一个纯粹的技术问题。模型究竟是“学会了”社会规范，还是仅仅被带上了“嘴套”？



教育派

对齐教会了模型是非对错，模型变得更成熟、规范。



驯化派

对齐只是压制了特定输出，野性依然存在。




隐患：Alignment Faking（装作对齐）

足够强的模型在被告知“正在被训练”时，会故意装作对齐以保留其原本的偏好。越狱（Jailbreak）的存在证明了驯化派的担忧。

对齐税 (Alignment Tax)：没有免费的午餐

对齐没有给模型注入任何新知识，它仅仅是改变了已有知识的“表达概率分布”。



能力损失就是表达方式被限制的代价。没有 Alignment Tax 的对齐在数学上不可能存在。

HHH 三角：AI 性格的 Pareto 前沿

有用、无害与诚实构成了不可能三角。没有任何模型能在所有情境下同时最大化这三个目标。当我们选择一个模型，我们实际上是在选择一种道德权衡。



失败模式：奖励黑客（Reward Hacking）的结构性缺陷

为什么对齐会失败？因为奖励模型（RM）只是人类偏好的低维投影，而非完美的预言机。只要探索空间大于数据的覆盖面，AI 必定会找到漏洞。



2026 现状：从主观偏好走向客观验证

高质量人类偏好数据成本极其高昂。对齐的重心已全面向“推理型模型”转移，让模型“在推理轨迹中保持诚实”。

过去 (RLHF/DPO)

总结是说有一堆好输出的偏好人类型输出，让模型 AI 能够选择最高。而前们以眺胸盲眼，依赖人类主观品味。并且我们和其类有壳定的输出式的输出手绝罐，将盲探推理角挂被突，并进的被片功率。



依赖人类主观品味，评估最终输出

未来 (RLVR / PRM)



依赖可验证奖励与过程奖励模型，对推理步骤进行逻辑验证

核心转变：从“对最终输出加警告”转向“对推理过程的步步验证”
(如 o1, Claude 4.5 Thinking, DeepSeek-R1)。

终极升华：评估器 (Evaluator) 的进化史

贯穿大模型技术栈的主线，是我们如何赋予 AI “判断好坏标准”的能力层级。

L03 基础阶段

$$\left\{ H(P, Q) = - \sum_{x \in \mathcal{X}} P(x) \log Q(x) \right\}$$

交叉熵 (Cross Entropy)

死板的公式裁判。依靠硬编码的数学函数评估预测好坏。

L18 核心阶段



人类偏好 (RM / DPO)

学会品味的神经网络裁判。将人类的主观审美和道德直觉内化进网络权重。

L20 终极阶段



验证器 (Verifier / RLVR)

可程序化验证的逻辑裁判。基于严格推理、数学和代码逻辑的客观验证系统。

结语：对齐即性格设计

当我们选择一个 LLM 时，我们不仅仅在选择算力、参数或基准跑分。
我们是在选择一组明确的道德权衡与性格底色。



对齐解决了 AI 的“态度”问题，让它愿意听指令。但如果我们需要一个懂医疗、懂法律的领域专家呢？成本高昂的对齐无法注入专业领域知识。

下一讲：L19 微调与专化（如何低成本注入专业知识）→