



生产级 RAG 架构设计与工程蓝图

从 AI 玩具到工业级大模型流水线的跃迁指南



核心范式决策：解决知识缺失与表达错误的不同路径



微调 (Fine-Tuning) / 闭卷考试

RAG (检索增强生成) / 开卷考试

知识更新:	需要重新训练大模型	知识更新:	实时更新向量知识库即可
可溯源性:	黑盒机制, 不知答案从何而来	可溯源性:	过程透明, 返回确切的原文引用
幻觉控制:	困难 (知识融合在参数中)	幻觉控制:	相对容易 (答案有据可查)

核心决策树：如果模型不知道某些事实——用 RAG。如果模型知道但表达方式或领域风格不对——用微调。生产环境通常将两者结合。

Scale: 16-W-0.880 8:00 08

冰山之下的工程现实：先检索，再生成的幻觉

$RAG = \text{Retrieval} + \text{Generation}$

Illusion

Pipeline Reality


忽略检索：模型无视提供的上下文，凭记忆捏造答案。

噪声干扰：检索结果中混入大量不相关内容，稀释注意力。

跨块断裂：关键答案恰好被切在两个文档片段的边界上。

Garbage in, garbage out 在 RAG 中极其致命。任何前端提示词的优化，都无法挽救底层流水线输入质量的崩塌。

RAG 系统的 6 阶段核心流水线



1. 加载 (Load) :
从 PDF, HTML, API
提取文本

2. 分块 (Chunk) :
决定检索原子粒度

3. 向量化 (Embed) :
文本转化为数学空间表示

4. 检索 (Retrieve) :
在毫秒级锁定 Top-K 证据


5. 增强 (Augment) :
构建带有上下文
的高质量 Prompt

6. 生成 (Generate) :
LLM 综合证据输出答案

注意: PDF 表格解析与 HTML 噪声清洗是最易引发全盘崩溃的环节

警告: 分块与检索是整个架构中最脆弱、最需要人工调参的两个工程瓶颈。

分块 (Chunking) 的工程权衡：信息密度与上下文完整性




切分策略：固定大小 vs 重叠窗口 vs 语义分块 vs 结构化分块


工程真理：没有万能的分块策略。单一的Chunk大小永远是RAG质量的上限瓶颈，生产环境必须按数据和查询类型使用多粒度混合分块。

突破上下文盲区：2024 核心创新 Late Chunking（延后分块）

传统分块 (Naive Chunking)



缺陷：局部编码，彻底丢失全局上下文位置。



延后分块 (Late Chunking)




优势：每个片段的向量都“知道”它在全文中的绝对位置。

性能提升：在长文档 (> 4K tokens) 上，Recall@10 提升高达 5-15%。

适用边界：对长技术文档、法律合同收益巨大；对短 (< 1K tokens) 收益接近零，且编码成本呈线性增长。

检索漏斗：混合检索与重排序（Reranking）的质量放大效应



粗筛（召回 Top-50）：
混合检索（Hybrid Search）


$$\alpha \cdot \text{Semantic} + (1 - \alpha) \cdot \text{BM25}$$

精排（重排序）：
Cross-Encoder (Reranker)


极致提纯（输出 Top-5）：
喂给 LLM 的高信噪比上下文

为什么重排序不可或缺?

无 Reranking :
Top-3 中真正相关的
片段约为 1.5 / 3



有 Reranking :
Top-3 中相关片
段跃升至 2.5 / 3



结论：相关性提升 67% (1.5 -> 2.5) 会带来用户感知质量 30-50% 的爆炸性提升。生成模型救不回劣质的 Top-5 证据。


架构的代际演进：从线性流水线到动态模块网络

第一代：Naive RAG (直线流水线)



路径：检索 -> 拼接 -> 生成。缺陷：质量不稳定，易产出幻觉，无多轮对话能力。


第二代：Advanced RAG (带预处理/后处理)



新增模块：引入查询改写（Query Rewriting）与上下文压缩（Context Compression）。


第三代：Modular RAG (动态分支网络 - 2024主流)

核心组件：
Router (路由判断)



架构质变：并非所有查询都需要检索。简单常识问题直接调用大模型，只有事实性问题才触发复杂的检索链路，从而大幅降低系统延迟与噪声干扰。

HyDE（假想文档嵌入）：让大模型充当语言红娘



机制

答案与答案之间的语义距离，往往远小于问题与答案之间的距离。

收益

在长尾、跨语言或极度复杂问题上，召回率可提升 5-15%。

代价

增加一次 LLM 调用延迟。在人名或精准编号检索时可能产生漂移有害影响。必须由 Router 按需启用。

RAGAS 评估三棱镜：拆解系统的盲盒

1. 上下文相关性 (Context Relevance)



核心考量：检索到的内容到底有没有用？
衡量指标：检索结果中高价值相关片段所占的精确比例。

2. 忠实度 (Faithfulness)



核心考量：生成的答案是否完全忠于检索内容？
衡量指标：大模型是否违背了给定的上下文，凭空捏造事实。

3. 答案相关性 (Answer Relevance)




核心考量：最终生成的结果真的回答了用户的提问吗？
衡量指标：最终答案面对原始问题的切题程度。

工程红线：只测生成质量是最致命的工程错误。如果检索阶段喂给模型的是垃圾，再强大的 LLM 也无法给出正确答案。评估必须分离度量。

大模型视角的贝叶斯推理：内部记忆与外部证据的博弈

Prior
(LLM 预训练记忆)
+
Evidence
(检索上下文)



= Posterior
(最终输出的答案)

无法主动纠错

LLM 无法自动区分高质量与低质量的检索片段。面对高噪声、无关或相互矛盾的上下文，模型只能被迫妥协，生成模糊且保守的答案。

撕裂的感知体验

糟糕的分块机制（答案恰好被切断在边界）在模型看来，就像被强迫阅读被撕碎的残页。诸如“基于上下文，似乎是...”的回复，正是系统分块错误的直接表征。


冲突时的信任博弈

当外部检索证据与 LLM 内部先验知识发生严重冲突时，模型会陷入权衡。如果检索内容包含极端荒谬的错误，安全对齐训练会驱使 LLM 拒绝遵循外部输入。




向量检索的死角：跨文档多跳推理（Multi-Hop）的失败

用户提问：
X 公司的所有创始人都在
哪些公司工作过？



技术诊断：单个片段的 Embedding 只能编码内部局部语义，绝对无法编码片段与片段之间的拓间的拓扑关系。面对全局综合性、关系型查询，单纯的语义相似度检索完全无能为力。

GraphRAG: 构建突破孤岛的全局知识拓扑



Microsoft 2024 Core Innovations

1 离线提取



使用 LLM 提前将海量文档提炼为 (实体, 关系, 实体) 的结构化三元组, 构建全局知识图谱。

2 图遍历机制



将查询解析为实体匹配与多跳遍历, 把跨文档提取的子图作为精确上下文喂给 LLM。

3 成果体现



在全局性与关系型问题上, 准确率相比纯向量 RAG 提升 30% 以上。GraphRAG 是向量检索的高阶补充, 而非替代。


SYSTEM: GraphRAG

DATE: 2024

APPROVED




Agentic RAG: 从单次命中到递归研究的未来范式



设计转变：让大模型掌握检索的绝对控制权。从“被动喂养单次文本”彻底转变为“主动探寻、自我纠错的多轮递归研究”。

生产级 RAG 架构全景决策树



RAG 给大模型装上了阅读海量资料的眼睛。但若要让它执行真实世界的任务，仅仅输出文字是远远不够的。下一步：给模型装上行动的双手 (Function Calling)。

SYSTEM: RAG Decision Tree

DATE: 2024

APPROVED

