


从说到做到： Function Calling 与 MCP 协议解码


LLM 时代的行动接口——赋予 AI
改变外部世界的能力



演进的瓶颈


RAG 让模型博学，但依然手无寸铁

现状：RAG 的被动流



The Action Gap
(行动鸿沟)


诉求：物理与数字世界的干预



核心洞察：纯文本的 Token 序列无法直接干预外部世界。模型需要一种结构化的行动接口。

架构重塑：决策与执行的物理隔离

架构的工程图台



为什么不直接让模型执行？

API 网关 / 安全隔离墙

- 安全隔离：拒绝赋予模型直接删库的系统级权限。
- 确定性计算：LLM 擅长意图推理，外部代码擅长精确的确定性计算。

微观机制：将自由文本约束为代数结构



警惕迷思：JSON Mode = 语法合法，但 $\neq$ 语义正确

模型仍可能产生参数幻觉或遗漏必填字段，Server-side 的业务逻辑校验绝对不可省略。

完整数据闭环：Function Calling 的 5 步反应式生命周期



Parallel Calling (并行调用)


在 Step 2 中, 模型可一次性输出多个 `tool\_call` 工单, 代码并行执行后统一在 Step 4 返回, 大幅降低系统延迟。

工程痛点爆发：M × N 适配噩梦

M 个 AI 应用




N 个外部工具



工程成本 = M × N

指数级的工程浪费：每一个交叉点都需要重新编写鉴权、重试与数据解析逻辑。


破局者 MCP: AI 工具生态的标准化总线



架构降维：从 $M \times N$ 转化为 $M + N$

假设 $M=100$, $N=100$ 。代码维护量从 10,000 个定制接口骤降至 200 个标准化实现。节省 50 倍开发工作量。

MCP 物理架构：四层垂直堆栈



核心法则：协议即生态。开发者只需编写一次 Server 逻辑，所有兼容 MCP 的 LLM 即可瞬间无缝调用。

MCP 三大核心原语：控制权权属诊断矩阵

控制方	LLM 模型主动	应用层被动	最终用户触发
核心原语	Tool (工具)	Resource (资源)	Prompt (提示模板)
触发场景	模型自主决策： 『我需要现在查询天气 API。』	系统隐式执行： 『启动时自动从服务器拉取最新文档。』	用户显式调用： 『用户输入斜杠命令/总结。』
传统架构类比	Function Calling	REST API GET 端点	System Prompt 动态注入

MCP 不仅仅是远程函数调用。 三者的有机结合才构成了 LLM 与外部世界交互的完整控制论抽象。


安全敞口：通过工具输出的 Prompt 注入



- ✓ **最小权限原则：严禁赋予任意代码执行权**
- ✓ **结果清洗 (Sanitization)：对工具返回内容进行强制过滤**
- ✓ **沙箱隔离 (Sandboxing)：在隔离环境中运行不可信的工具逻辑**
- ✓ **Human-in-the-Loop：敏感物理操作必须前置人工确认步骤**


工程物理极限：注意力瓶颈与分层路由

问题 (The Problem)



随着 System Prompt 被海量 Schema 拉长，模型的注意力被指数级稀释。

解决方案 (The Solution)



将扁平列表重构为树状路由分发架构，避免将 30+ 工具直接塞入单次上下文。

堆砌 Tool 是必然导致性能降级的反模式。深度调优 Tool Description 并引入分层路由，是被严重低估的高 ROI 投入点。


下一代范式：从 API Schema 到 Computer Use

基于 API 的代码级交互




- 行动空间：万级（专属预定义 API）
- 优势：计算快、精确度高、极高稳定性

基于视觉的 GUI 级交互



- 行动空间：百万级飞跃（全人类所有 GUI 软件）
- 代价：极慢、昂贵推理成本、易受 UI 变动干扰

2026 行业生态快照：MCP 已成为绝对事实标准




模型	Function Calling 质量	MCP 原生支持	并行调用 (Parallel)
GPT-5	■ ■ ■ ■ ■	是	是
Claude 4.5 Sonnet	■ ■ ■ ■ ■	是 (第一方)	是
Gemini 3.0 Pro	■ ■ ■ ■ □	是	是
Llama 4 405B	■ ■ ■ □ □	是	是

认知闭环：AI 行动接口层级技术栈



让大语言模型拥有改变物理世界的能力并非一蹴而就，而是一层层协议与数学约束构建起的现代技术奇迹。

下一讲预告：从反应式接口到自主思考主思考架构



单次 Function Calling 仅仅是反应式的执行指令。面对诸如『分析代码库并编写架构文档』等复杂工程，模型需要的不仅是『手』，还需要一个完整的决策思考闭环。

L26 预告 | AI Agent: 从工具接口走向自主智能体