


AI Agent: 从工具到自主智能体

跨越单次调用的边界，
构建“思考-行动-评估”的持续循环



赐予大脑：超越“反应式”的局限

反应式 (Function Calling)



调用次数：
通常 1-2 次

执行逻辑：
无规划（反应式）

错误处理：
失败即终止

状态管理：
单轮上下文

主动式 (Agent)



调用次数：
可能数十次循环


执行逻辑：
分解任务、动态决策

错误处理：
反思原因、自我纠错

状态管理：
跨多轮积累长期记忆


Function Calling 给了模型“手”，但 Agent 把它放入了持续循环的“大脑”中。

智能体解剖学：四大核心要素



$$\text{Agent} = \text{LLM} + \text{Tools} + \text{Memory} + \text{Loop}$$

核心引擎：PGE 控制框架



PGE 不是某个具体软件的名字，而是几乎所有成功智能体的通用设计范式。


评估者的终极演进 (The Evolution of the Evaluator)



ReAct 范式：外部化的“慢思考”



仅依赖内部知识，无法验证假设。




Reason + Act 交替：每次行动前，必须用文字输出“为什么这样做”。

获取新信息：Action 获取外部数据，弥补 LLM 内部知识的空白。

外部化的 System 2：强迫模型“先想再做”，使决策过程可解释、可审计、可追踪。

注意：适合复杂长程任务；简单短任务用 ReAct 会导致冗余推理和高 Token 消耗。


Reflexion: 基于自然语言的强化学习 (Verbal RL)



数学本质：等同于“软参数更新”。无需梯度下降（无权重改变），通过 In-Context Learning 累积经验，避免重复犯错。


系统架构：智能体的组织模式

单智能体 (Single)




1 个 LLM + 一组工具。适用于任务明确、工具 < 15 个的场景。

路由模式 (Router)



类似医院“分诊台”，对请求分类并转发给专门处理器。

层级模式 (Orchestrator-Worker)



“经理”负责规划分配，“工人”负责具体执行。

Multi-Agent 警告：复杂度的非线性爆炸



- 多智能体系统必然面临分布式系统的根本难题：通信开销、状态同步困难、共识难难达成。
- 每个 Agent 都需阅读其他 Agent 的消息，导致 Token 消耗呈指数级上升。

70%+ 的任务中，单智能体表现持平甚至胜出。
先用单 Agent，多 Agent 始终是最后手段。

临床诊断矩阵：四大失败模式

症状 (Symptom)	病因 (Cause)	处方 (Antidote)
无限循环 (Infinite Loop)	OOD 情境下反复执行同动作	设定 max_steps 与 Token 预算硬上限。
工具幻觉 (Hallucination)	调用不存在的工具或非法参数	执行严格的 Schema 验证并返回明确报错提示。
奖励欺骗 (Reward Hacking)	找到“通过评估”但未完成任务的捷径	实施多维度 Evaluate (测试通过率 + 代码质量 + Diff)。
上下文爆炸 (Context Explosion)	长程任务积累过多对话历史	定期压缩上下文，或使用子智能体隔离执行。

深度剖析：智能体的数学本质


Agent 不仅仅是聪明的 LLM，它是图灵完备 LLM + 外部世界状态机。
它将有界深度的电路升级为无界计算。

LLM	≡	Policy (策略)
Tools	≡	Environment (环境)
Verifier	≡	Reward (奖励)

Agent 综合能力 = LLM 基础质量 (Policy) × 循环工程质量 (Loop)

循环框架的工程质量对最终效果的贡献，几乎等同于大模型本身的能力。

2026 生态切片：赛道与前沿产品



关键趋势 (Key 2026 Trends)



必须依赖顶级 Reasoning 模型 (o3 / R1 / Claude 3.5+)。



核心范式转向 Computer Use (视觉输入、键鼠操作)。



焦点转向 Long-horizon (长程) 任务执行。

剥离炒作：清醒的工程认知

Funnel of Failure

Step 1: 95%

Step 5: ~77%

Step 10:
60%

长任务雪崩：即使单步准确率达到95%，串联10步后的端到端成功率也仅剩60%。复杂任务越多，失败率呈指数级上升。


2026 现实挑战

- **领域局限：**窄且清晰任务表现优异，但通用多工具协作仍<60%。
- **高昂成本：**一次复杂的 Devin 级长任务执行消耗可达 \$5 - \$50。
- **调试黑盒：**Agent 失败时，极其难以准确定位是 Plan、Ground 还是 Evaluate 环节出错。


核心原则：构建自动化系统的基石



下一步：能力装配与上下文保卫战



当 Agent 需要 50+ 种工具时，全部塞入 Prompt 会引发上下文爆炸；只给 5 个工具又会导致“没有手”。



如何让智能体按需装配能力？如何将冗长的任务委托给独立的子智能体以拯救主下文？

预告：L27 - Agent Skills, Memory, and Protocols.