


从单一文本向量，到图文音视的统一几何空间（2024-2026 技术演进快照）

从单一文本向量，到图文音视的统一几何空间（2024-2026 技术演进快照）




真实世界不是纯文本的——只有文字的Agent是盲目的

传统架构：纯文本局限




L26 多模态 PGE 架构扩展



诊断标签：多模态的本质，是将Agent的感知通道扩展至物理世界，输入空间升维。

基石一：CLIP — 4亿免费图文对构建的对称桥梁

打破人工打标签限制，实现零样本分类（Zero-shot）



基石二：Diffusion 模型 — 概率密度场中的墨水倒放


前向加噪：滴入墨水（逐步破坏结构）



终点：全新生成的图像


起点：纯随机噪声

去噪：墨水倒放（Score Matching / SDE 随机微分方程）



【告警】 扩散模型不是从数据库里搜图拼接，而是从纯噪声中现场雕刻图像。

扩散操控台：CFG (Classifier-Free Guidance) 与条件引力场



$$\hat{\epsilon}_t = \epsilon_{\theta}(x_t, \emptyset) + s \cdot [\epsilon_{\theta}(x_t, c) - \epsilon_{\theta}(x_t, \emptyset)]$$

多样性高, 易偏题




$s \approx 7.5$



贴合文本, 多样性低

基石三：VLM 架构 —— 让大语言模型长出眼睛

对于LLM来说，图像就是一段视觉语言的文字。




物理账单：视觉算力陷阱与Token经济学

文本输入：~300 Tokens


1024x1024 图像：4096 Tokens

被硬切分为 4096 个 Patches



Agent 工程实践：多模态 workflows 与 ComfyUI

非程序员的多模态组装工厂：模块化、节点化、可视化




2026 战局快照：主流多模态模型能力矩阵

模型	文本	图像理解	图像生成	语音	视频理解	视频生成
GPT-5	●	●	◐ (DALL-E 4)	●	●	◐
Gemini 3.0 Pro	●	●	● (Imagen 4)	●	● (1M+)	● (Veo 3)
Claude 4.5	●	●	○	◐	◐	○
Qwen3-VL	●	●	○	◐	●	○

趋势洞察：「原生多模态」正在取代「后接式拼接」。模型在预训练阶段就吞吐多模态数据，跨模态推理的几何对齐远强于后期缝合。


视频生成的分野：Diffusion (DiT) vs Autoregressive (AR)

阵营一：Diffusion Transformer (DiT)



代表作：Sora, Veo 3, Kling

阵营二：Autoregressive (AR)



代表作：VideoPoet, Cosmos


【当前主流】物理规律涌现强，但算力消耗极高。➡



【潜力路线】占据精确编辑性与可控性优势。

技术边界一：视频理解的算力陷阱

为什么AI看完并理解整部电影如此艰难？




残酷的数学推导：

- 1 分钟 30fps 视频 = 1800 帧
- 每帧 (1024x1024) = 4096 Tokens
- ➔ 1 分钟视频 $\approx$ 7.4M Tokens
(远超当前模型 2M 的物理极限)

必须付出的工程妥协：



[抽帧]
漏掉关键动作



[降分辨率]
丧失核心细节



[视频压缩]
丢失原始语义

结论：视频理解的根本瓶颈不是模型智力，而是 Token 经济学。


技术边界二：隐蔽的英语中心偏见与浅层对齐

系统边界告警：

1. 源头污染：CLIP 训练数据（4 亿图文对）中超过 90% 为英文（Alt-text / Caption）。
2. 连锁失效：导致专有领域（如中医理论、中国古文物、复杂几何推演）的多模态能力骤降。
3. 迷思破除：多模态相加 $\neq$ 真正的跨模态深度推理。

全局合成：LLM 时代的精密工程合奏

从「用LLM处理文字」跨越到「用LLM理解物理世界」



核心洞察：多模态从来不是简单的加法，它是三种底层数学机制的巅峰对齐。

你的 AI 现在能看、能听、能说、能画。
但你有没有想过……
所有这些能力，都是你一行行用代码写出来的。
如果 AI 能自己写代码呢？

—