



评估、监控与 LLMOps — 从能用到可靠

Laboratory

Production



一个幻觉率 5% 的模型在实验室是可以发表的论文，在生产环境则是每小时几十次的事故。



INPUT
DATA

LLM
(LAB)

OUTPUT
(PAPER-READY)

实验室与生产环境之间，隔着整个工程体系

实验室环境

幻觉率 (3%)



前沿研究的突破口



延迟要求




等 30 秒出结果无所谓



计算成本




跑通一次即可



并发规模



单体用户，单线程



生产环境

ALERT


每 33 次对话引发一次客诉灾难



每 33 次



尾延迟 (P99) 必须低于 500ms



\$2-4/小时持续燃烧，空跑即烧钱



成百上千用户瞬间涌入的洪峰



从“能用”到“可靠”，唯一的桥梁是 LLM Ops。

模型只是引擎，LLMOps 是整辆赛车


传动系统（推理服务）
PagedAttention / Batching

[Model.generate()]







遥测仪表盘（生产指标）
TTFT / TPS / 缓存利用率

安全刹车（幻觉治理）
Grounding & Fact-checking

质检车间（评估体系）
五层 Evaluator 管线



推理服务化的三大底层支柱

PagedAttention	Continuous Batching	Speculative Decoding
核心机制  虚拟内存分页	核心机制  动态插队批处理	核心机制  小模型草拟 + 大模型验证
物理隐喻  从 8 人大桌预留, 改为自助餐按需入座	物理隐喻  用无缝旋转门, 替代定时长途客车	物理隐喻  免费的 Pareto 提速黑科技
代数级性能跃升 显存利用率 30% → 90% 	代数级性能跃升 单卡吞吐量翻倍 (~40% → 80%) 	代数级性能跃升 延迟显著降低 2-4x 

这些不是锦上添花的功能, 这是所有现代推理引擎 (vLLM / TGI) 的默认生存法则。
手写 KV Cache 已成为反模式。



PagedAttention: 终结高达 97% 的显存浪费

传统连续分配

8 TOKENS/TABLE





95-99%
显存锁定/浪费



FIXED BLOCK ALLOCATION

虚拟内存分页

DYNAMIC MAPPING



FRAGMENTATION: <1%
TELEMETRY: <1%
FRAGMENTATION: <12%


16 tokens/页

ON-DEMAND ALLOCATION

【同等硬件并发能力提升 3-5 倍，推理的单位成本随之发生断崖式下跌。】

打破线性等待的算力黑洞

Continuous Batching




Revolving Door



摒弃长途客车模式（等待最慢任务）

Speculative Decoding




Draft Model / 7B

Target Model / 70B

⚙️ [严格保证输出分布完全等价的同时，几乎免费获取算力与速度的飞跃。] ⚙️

决定产品生死的遥测硬指标



TTFT (首Token时间)

AI 反应快不快 (交互底线)



TPS (每秒Token数)

AI 说话流不流畅 (必须超越人类阅读速度)




KV Cache 利用率

运营成本底线 (决定单卡 ROI)

训练是一次性成本，推理是持续燃烧的成本。推理优化不是优化体验，是优化生存。

评估体系的 18 讲演化史：从变量到车间

复杂度上升 100 倍，覆盖维度上升 10 倍——**Evaluator** 不再是一个数字，而是一套质量保障体系。



L03: 损失函数
(100% 自动标量反馈)

L18: RLHF 奖励模型
(基于人类偏好训练的神经网络评委)


L20: 推理模型内置验证
(思维链自我交叉检查)

L26: PGE 框架显式化
(Agent Loop 多维环境反馈)


L31: 生产级 Evaluator 流水线
(30-90% 自动, 覆盖系统工程)

生产环境的五层评估金字塔

[16:9]



黑灯工厂 (Dark Factory)：当人类退出审查循环



可观测性：刺透黑盒的 X 光透视


无 Trace 的黑盒



错误答案

只知道它答错了，毫无头绪。

有 Agent Trace 的 X 光透视



可观测性四大支柱

1. Prompt 版本回溯


2. Token 成本秒级监控

3. 异常突增检测


4. Agent 全链路 Trace
(唯一的故事黑匣子)

幻觉治理三板斧：检测、缓解与标注

STAGE 1: GROUNDING (接地)
- 通过 RAG 将模型锚定至物理现实。



STAGE 2: CITATION (引用)
- 强制生成内容与来源形成可验证的精确映射。



STAGE 3: FACT-CHECKING (核验)
- 生成后的独立验证模块，扫描逻辑矛盾。



Output Mockup

根据最近的系统分析报告，工业自动化流程在提高效率的同时，也引入了新的风险点。报告特别指出，某些AI驱动的决策模块可能在特定条件下产生幻觉。

⚠️ 待验证 (Confidence < Threshold)
建议的缓解策略包括加强人工介入和引入外部事实核查机制，以确保系统输出的可靠性。


该报告同时确认，通过实施严格的数据治理和引用验证，可以将幻觉风险降低至可接受水平。✅ [已核实信息]

幻觉治理的成本与质量柏拉图曲线



必须接受接近 0 但绝不为 0 的现实。在概率生成架构下，追求绝对的 0 幻觉是不切实际的工程执念。

2026 年 LLMOps 工业蓝图与合规生态




Deep Dive: Inspect

由 Anthropic 与英国 AI 安全院开源。

它将职责分离的思想完美映射为做事的 Solver 与评判的 Scorer。

这意味着，你的产品级评估代码，正在与前沿模型的 EU AI Act 风险合规评估使用同一种系统语言。

基础设施已经就绪，然后呢？



推理成本正经历断崖式下跌。评估管线与监控雷达已将 AI 牢牢锁定在可靠的轨道上。我们终于跨越了从实验室到生产环境的死亡之谷。

当系统不仅能处理文本，还能生成图像、视频、3D，甚至构建物理规则的世界...

当创造的边际成本趋近于零，谁来决定什么值得被创造？

L32 下一站预告：生成式 AI 的版图。