



安全、红队与可解释性

我们能理解自己创造的系统吗？




可解释性不是锦上添花，而是安全的根基。
你不理解的系统，就不可能真正控制。

物理世界抬高了赌注：从“说错话”到“做错事”



聊天机器人幻觉的最坏结果：
用户读到错误信息（影响可逆）。



具身智能或自动化 Agent 幻觉的最坏结果：
物理破坏或系统级瘫痪（真实伤害）。

当 AI 能操控物理世界，错误 = 真实伤害。

定义技术边界：三个可量化的核心安全难题

越狱 (Jailbreak)



定义：绕过安全对齐生成被拒内容。

诊断：对齐只是脆弱的“表面涂层”，而非内在约束。



幻觉 (Hallucination)



定义：一本正经地编造虚假信息 (GPT-4o/Claude 3.5 幻觉率约 3-5%)。

诊断：当前自回归架构的内在缺陷，模型缺乏“不确定性意识”。



对齐税 (Alignment Tax)




定义：安全对齐导致的能力下降与过度审查。

诊断：HHH（有用/无害/诚实）之间的永恒张力，安全不是免费的。



越狱的代数根源：RLHF 改变的是输出概率，而非内部知识


被压制的概率从未变成零



$$P_{\text{aligned}}(y | x) = \frac{P_{\text{base}}(y | x) * \exp\left(\frac{r(y, x)}{\beta}\right)}{Z}$$


- 攻击者只需找到一条提示词路径，重新激活这些沉睡的概率。
- $P_{\text{aligned}}(y | x) = P_{\text{base}}(y | x) * \exp(r(y, x) / \beta) / Z$

幻觉的架构缺陷：Next-Token 优化的是概率，而非真相



模型没有“不确定性意识”——它自己无法区分“我知道”与“我在编造”。
RAG 只是缓解，无法根除。

提示注入 (Prompt Injection) : LLM 应用时代的 SQL 注入



OWASP Top 1

提示注入是 2023 LLM 应用安全 Top 10 首位风险。



注意力盲区


Attention 机制是“信任盲”的，它对所有 Context token 赋予平等的权重，不区分系统提示与外部工具输出。



间接注入

当 Agent 能联网或读邮件时，任何外部数据源都是致命的攻击向量。

红队方法论：给大模型做结构化“地震测试”



红队测试不是证明系统安全，而是穷尽手段找出系统“最多能坏到什么程度”。

可解释性的范式转移：从“观察黑箱”到“逆向大脑”


传统可解释性 (Traditional Explainability)



“看到了什么”

依赖 Attention Maps 和 SHAP 值，只解释哪些输入影响了输出。

机制可解释性 (Mechanistic Interpretability)



“它是怎么运转的”

像生物学家研究细胞一样，逆向工程神经网络内部具体的神经元、特征与因果计算回路。

打开黑箱的三个步骤：Anthropic 的机制可解释性突破

第一步：叠加 (Superposition)


一个神经元同时编码多个正交概念。

第二步：字典学习 (SAE)

稀疏自动编码器作为分解棱镜。

第三步：特征提取 (Features)

提取出单义的、人类可理解的独立概念
(Claude 3 Sonnet 提取了 ~3300 万特征)。



从叠加的高维混沌中，还原出清晰的因果计算回路。

概念验证：Golden Gate Claude 证明内部特征可被操控


金门大桥特征激活值



这项实验历史性地证明：特征不仅可以被精确识别，还可以通过人为修改激活值，从物理底层彻底改变模型的行为。


2025 工程加速：可解释性走向 SaaS 与生产力

1. JumpReLU SAE



传统 ReLU 存在死特征；JumpReLU 引入二进制阈值激活，干净利落（要么响么不响），特征对齐质量提升 5-10 倍。

2. Crosscoder（跨层动画）




突破单层限制，追踪概念在整个 Transformer 架构中的完整流转生命周期（从快照升级为动画）。

3. Goodfire 商业化（SaaS）




开发者上传模型，直接获取已标注的特征字典与操控 API。应用层开发者也能轻松压制有害特征。

理解赶上创造的竞赛：安全的核心张力



每年都有更多未知的黑箱区域被部署。如果可解释性无法追平能力跃升的速度，系统性失控风险将呈指数级累积。

2026 监管现实：EU AI Act 对工程架构的倒逼



工程合规必选项：

- ☒ - 可证明的评估流水线 (PGE)
- ☒ - 完整的红队测试报告
- ☒ - 数据治理日志
- ☒ - 真人监督 (Human-in-the-loop)

行业安全红线：Frontier Safety 框架与 ASL 评级



ASL-3 触发状态: 2025-02,
Claude Opus 4 触发 ASL-3
评级。


对 Agent 开发者的影响: 处
于下游应用层的开发者, 现
在必须向上游 API 提供商提
交详细的 **Use-case 申报**, 并
接受实时滥用检测约束。

总结：在透明的玻璃盒中重建信任

2. 红队化被动为主动
通过结构化对抗测试，穷尽系统边界。

1. 对齐并非本质安全

RLHF 只是表面涂层，
越狱与幻觉源于自回归
的深层数学机制。



3. 可解释性是唯一解

只有彻底打开黑箱，逆向
计算回路，才能实现
真正的安全控制。

“真正的控制，始于真正的理解。”